BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC KINH TẾ QUỐC DÂN
VIỆN ĐÀO TẠO TIÊN TIẾN, CHẤT LƯỢNG CAO & POHE

BÀI TẬP NHÓM
KHOA HỌC DỮ LIỆU TRONG KINH TẾ VÀ KINH DOANH

CHỦ ĐỀ 9: ADULT CENSUS INCOME
NHÓM 11

Lớp: Logistics và Quản lý chuỗi cung ứng CLC 66B

Đỗ Hoài An - 11243559

Dương Minh Anh - 11241163

Nguyễn Quỳnh Anh - 11245333

Hà Tiến Đạt - 11243282

Nguyễn Thị Vân - 11242874

Github: GitHub - ngqanh06/KHDL-GROUP-11-TOPIC-9 · GitHub

DANH SÁCH THÀNH VIÊN

Mã sinh viên	Họ và tên	Mức độ đóng góp
11243559	Đỗ Hoài An	100%
11241163	Dương Minh Anh	100%
11245333	Nguyễn Quỳnh Anh	100%
11243282	Hà Tiến Đạt	100%
11242874	Nguyễn Thị Vân	100%

MỤC LỤC

A. Giai đoạn 1: Thu thập và đánh giá dữ liệu ban đầu....4
1. Nguồn dữ liệu....4
1.1. Tập dữ liệu đã lựa chọn....4
1.2. Cấu trúc file....4
1.3. Mô tả thuộc tính:....4
1.4. Mục tiêu bài toán....5
2. Kiểm tra hiện trạng dữ liệu....5
2.1. Cấu trúc và kiểu dữ liệu từng trường....5
2.2. Thống kê mô tả các biến số....6
2.3. Giá trị khuyết thiếu (missing values)....6
2.4. Dòng trùng lặp....7
2.5. Tính nhất quán dữ liệu....7
2.6. Phân phối, giá trị bất thường và vấn đề chất lượng khác....8
3. Tổng hợp đánh giá và định hướng cho giai đoạn tiếp theo....8
4. Phân tích quy trình kiểm tra dữ liệu....9
4.1. Chuẩn bị môi trường và nạp dữ liệu....9
4.3. Phát hiện và đo lường giá trị khuyết ẩn....12
4.4. Dòng trùng lặp, biến mục tiêu và nhất quán logic....13
B. Giai đoạn 2: Tiền xử lý và làm sạch dữ liệu....14
1. Tổng quan giai đoạn 2:....14
2. Giai đoạn tiền xử lí và làm sạch dữ liệu:....14
2.1. Chuẩn bị môi trường và kiểm tra chất lượng dữ liệu:....14
2.2. Xử lý giá trị thiếu:....17
2.3. Xử lý dữ liệu trùng lặp:....18
2.4. Phát hiện và phân tích ngoại lệ (Outliers):....19
2.5. Biến đổi dữ liệu để giảm độ lệch:....21
2.6. Loại bỏ cột dư thừa và lưu bản sạch:....22
2.7. Mã hóa biến phân loại:....22
2.8. Chia tập dữ liệu và chuẩn hóa:....23
2.9. Tổng kết và lưu kết quả:....24
C. Giai đoạn 3: Phân tích và trực quan hóa....24
1. Bức tranh tổng thể....24
2. Giai đoạn 1: tự tải dữ liệu....25
3. Giải thích từng ô....25
4. Phân tích chi tiết kết quả và kiểm định các giả thuyết....31
4.1. Nhận xét Hình 1: Phân bố nhóm thu nhập....31
4.2. Nhận xét Hình 2: Tuổi tác và thu nhập....31
4.3. Nhận xét Hình 3: Tỷ lệ thu nhập >50K theo bậc học....32
4.4. Nhận xét Hình 4: Giới tính và thu nhập....33

4.5. Nhận xét Hình 5: Giờ làm việc và thu nhập..... 34
4.6. Nhận xét Hình 6: Hôn nhân, nghề nghiệp và thu nhập.....36
4.7. Nhận xét Hình 7: Tỷ lệ >50K theo nhóm tuổi và trình độ học vấn..... 37
4.8. Nhận xét Hình 8: Các yếu tố liên quan đến thu nhập..... 38
5. Kết luận Giai đoạn 3..... 39
D. Giai đoạn 4: Đánh giá tác động và khuyến nghị..... 40
1. Tóm tắt các phát hiện nổi bật nhất.....40
1.1. Về chất lượng dữ liệu (Giai đoạn 1 và 2)..... 40
1.2. Về các yếu tố liên hệ với thu nhập (Giai đoạn 3)..... 40
1.3. Yếu tố liên hệ mạnh nhất với thu nhập.....41
2. Đề xuất giải pháp mang tính ứng dụng thực tế.....42
2.1. Giáo dục và đào tạo nghề.....42
2.2. Lộ trình sự nghiệp cho người trẻ..... 43
2.3. Nhóm 55 tuổi trở lên.....43
2.4. Bình đẳng giới..... 43
2.5. Giờ làm việc.....43
2.6. Nhóm không khai báo việc làm (Unknown).....43
2.7. Ứng dụng mô hình dự đoán thu nhập..... 44
2.8. Bảng tóm tắt khuyến nghị.....44
3. Giới hạn của tập dữ liệu và hướng mở rộng..... 45
3.1. Các giới hạn cần nêu rõ..... 45
3.2. Hướng mở rộng trong tương lai.....46
4. Kết luận chung của bài..... 47

A. Giai đoạn 1: Thu thập và đánh giá dữ liệu ban đầu

1. Nguồn dữ liệu

1.1. Tập dữ liệu đã lựa chọn

Bài tập sử dụng bộ dữ liệu Adult (còn gọi là Census Income), trích xuất từ cơ sở dữ liệu điều tra dân số Hoa Kỳ năm 1994 và được đăng tải trên Kaggle (nguồn gốc từ UCI Machine Learning Repository). Đây là bộ dữ liệu chuẩn cho bài toán phân loại nhị phân trên dữ liệu bảng (tabular data), có kết hợp cả biến số và biến phân loại, có giá trị khuyết thiếu và mất cân bằng nhãn, phù hợp để thực hành đầy đủ quy trình khoa học dữ liệu.

1.2. Cấu trúc file

- Dữ liệu được cung cấp trong một file duy nhất: adult.csv (mã hóa UTF-8, phân tách bằng dấu phẩy, có dòng tiêu đề).
- Quy mô: 32.561 quan sát (dòng) × 15 thuộc tính (cột).
- Mỗi dòng là một cá nhân trưởng thành được khảo sát; không có cột định danh (ID) riêng.
-Vì chỉ có một file nên không phát sinh việc gộp bảng qua khóa chính/khóa ngoại.

1.3. Mô tả thuộc tính:

STT	Thuộc tính	Loại	Ý nghĩa
1	age	Số nguyên (liên tục)	Tuổi
2	workclass	Phân loại danh nghĩa	Khu vực/loại hình việc làm (Private, Self-emp, Gov…)
3	fnlwgt	Số nguyên (liên tục)	Trọng số mẫu của cuộc điều tra (số người trong tổng thể mà dòng này đại diện)
4	education	Phân loại thứ bậc	Trình độ học vấn cao nhất
5	education.num	Số nguyên (rời rạc)	Mã số hóa của education
6	marital.status	Phân loại danh nghĩa	Tình trạng hôn nhân
7	occupation	Phân loại danh nghĩa	Nghề nghiệp
8	relationship	Phân loại danh nghĩa	Vai trò trong gia đình
9	race	Phân loại danh nghĩa	Chủng tộc
10	sex	Nhị phân	Giới tính
11	capital.gain	Số nguyên (liên tục)	Lãi vốn
12	capital.loss	Số nguyên (liên tục)	Lỗ vốn
13	hours.per.week	Số nguyên (liên tục)	Số giờ làm việc mỗi tuần
14	native.country	Phân loại danh nghĩa	Quốc gia gốc
15	income	Nhị phân (biến mục tiêu)	Thu nhập: <=50K hoặc >50K

Tổng cộng: 6 thuộc tính số và 9 thuộc tính phân loại (trong đó income là nhãn).

1.4. Mục tiêu bài toán

- Loại bài toán: phân loại nhị phân có giám sát (supervised binary classification).
- Mục tiêu: dự đoán một cá nhân có thu nhập hằng năm trên 50.000 USD (>50K) hay không, dựa trên 14 thuộc tính nhân khẩu học, học vấn và việc làm.
- Phân bố nhãn: <=50K có 24.720 quan sát (75,92%); >50K có 7.841 quan sát (24,08%). Nhãn mất cân bằng khoảng 3:1, do đó khi đánh giá mô hình cần dùng các thước đo như Precision, Recall, F1, ROC-AUC thay vì chỉ dùng Accuracy (mô hình luôn đoán <=50K đã đạt khoảng 75,9%).
- Ý nghĩa ứng dụng: hỗ trợ phân tích các yếu tố ảnh hưởng đến thu nhập (học vấn, nghề nghiệp, giờ làm, tình trạng hôn nhân…) và là ví dụ điển hình để thảo luận về tính công bằng của mô hình (do có các thuộc tính nhạy cảm như sex, race).

2. Kiểm tra hiện trạng dữ liệu

2.1. Cấu trúc và kiểu dữ liệu từng trường

Dữ liệu được đọc bằng pandas, kết quả: 32.561 dòng, 15 cột, 6 cột kiểu số nguyên (int64) và 9 cột kiểu chuỗi (string).

Thuộc tính	Kiểu hiện tại	Kiểu hợp lý	Nhận xét
age	int64	Số	Phù hợp
workclass	string	Phân loại	Phù hợp
fnlwgt	int64	Số	Phù hợp; là trọng số, không phải đặc trưng mô tả cá nhân
education	string	Phân loại thứ bậc	Nên sắp xếp theo thứ tự trình độ
education.num	int64	Số rời rạc/thứ bậc	Trùng thông tin với education
marital.status	string	Phân loại	Phù hợp
occupation	string	Phân loại	Phù hợp
relationship	string	Phân loại	Phù hợp
race	string	Phân loại	Phù hợp
sex	string	Nhị phân	Có thể mã hóa 0/1
capital.gain	int64	Số	Phù hợp
capital.loss	int64	Số	Phù hợp
hours.per.week	int64	Số	Phù hợp
native.country	string	Phân loại	Nhiều mức (41 nước), cần gộp nhóm khi mã hóa

Thuộc tính	Kiểu hiện tại	Kiểu hợp lý	Nhận xét
income	string	Nhị phân	Cần mã hóa thành 0/1

2.2. Thống kê mô tả các biến số

Thuộc tính	Trung bình	Độ lệch chuẩn	Min	Trung vị	Max	Độ lệch (skewness)
age	38,58	13,64	17	37	90	0,56
fnlwgt	189.778	105.550	12.285	178.356	1.484.705	1,45
education.num	10,08	2,57	1	10	16	−0,31
capital.gain	1.077,6	7.385,3	0	0	99.999	11,95
capital.loss	87,3	403,0	0	0	4.356	4,59
hours.per.week	40,44	12,35	1	40	99	0,23

2.3. Giá trị khuyết thiếu (missing values)

Phát hiện quan trọng: hàm kiểm tra giá trị rỗng thông thường (isna()) trả về 0 cho mọi cột, nhưng điều này không có nghĩa là dữ liệu đầy đủ. Dữ liệu gốc mã hóa giá trị khuyết bằng ký tự "?", nên pandas coi đó là một chuỗi hợp lệ. Sau khi đếm riêng ký tự "?":

Thuộc tính	Kiểu dữ liệu	Số giá trị khuyết	Tỷ lệ khuyết (%)
occupation	chuỗi	1.843	5,66
workclass	chuỗi	1.836	5,64
native.country	chuỗi	583	1,79
age	int64	0	0,00
fnlwgt	int64	0	0,00
education	chuỗi	0	0,00
education.num	int64	0	0,00
marital.status	chuỗi	0	0,00
relationship	chuỗi	0	0,00
race	chuỗi	0	0,00
sex	chuỗi	0	0,00
capital.gain	int64	0	0,00
capital.loss	int64	0	0,00

Thuộc tính	Kiểu dữ liệu	Số giá trị khuyết	Tỷ lệ khuyết (%)
occupation	chuỗi	1.843	5,66
hours.per.week	int64	0	0,00
income	chuỗi	0	0,00
Tổng số ô khuyết		**4.262**	**0,87** (trên 488.415 ô)

- Số dòng có ít nhất một giá trị khuyết: 2.399 dòng, chiếm 7,37% tổng số quan sát.
- Cả 3 cột có khuyết đều là biến phân loại.
- Cơ chế khuyết không ngẫu nhiên hoàn toàn: 1.836 dòng khuyết workclass đều đồng thời khuyết occupation. Ngoài ra có thêm 7 dòng khuyết occupation nhưng workclass = Never-worked (hợp lý về nghiệp vụ: người chưa từng đi làm thì không có nghề nghiệp). Điều này cho thấy hai cột khuyết cùng nhau, thường ở nhóm không đi làm hoặc không khai báo việc làm (ví dụ nhóm tuổi 90, 82, 66 ở các dòng đầu file).
- Hướng xử lý đề xuất (thực hiện ở giai đoạn tiền xử lý): (i) chuyển "?" thành giá trị khuyết chuẩn (NaN); (ii) giữ lại như một nhóm riêng "Unknown" cho workclass/occupation vì khuyết có tính hệ thống và có thể mang thông tin; (iii) với native.country (1,79%) có thể điền theo mode (United-States) hoặc gộp nhóm; (iv) so sánh với phương án loại bỏ dòng khuyết (mất 7,37% dữ liệu) bằng kiểm định hiệu quả mô hình.

Sau bước 3, isna() mới phản ánh đúng thực tế: workclass 5,64%, occupation 5,66%, native.country 1,79%, và 2.399 dòng (7,37%) có ít nhất một ô khuyết, khớp với bảng ở trên.

2.4. Dòng trùng lặp

Có 24 dòng trùng lặp hoàn toàn (chiếm khoảng 0,07%). Do bộ dữ liệu không có cột ID nên các dòng này có thể là các cá nhân khác nhau có cùng đặc điểm (đặc biệt khi fnlwgt trùng thì nhiều khả năng là bản sao). Cần xem xét và loại bỏ ở bước làm sạch.

2.5. Tính nhất quán dữ liệu

- Nhất quán giữa các file (khóa chính/khóa ngoại): không áp dụng vì dữ liệu chỉ gồm một bảng duy nhất, không có phép nối. Dòng dữ liệu không có khóa định danh nên không thể kiểm tra trùng khóa chính; chỉ kiểm tra được trùng toàn bộ bản ghi (mục 2.4).

- Nhất quán nội bộ giữa các thuộc tính:

Kiểm tra	Kết quả	Kết luận
education ↔ education.num	Ánh xạ 1–1 hoàn hảo: 16 mức education tương ứng đúng 16 mã số (Preschool = 1 … Doctorate = 16), không có mâu thuẫn	Nhất quán; hai cột dư thừa thông tin (chỉ nên giữ một cột khi huấn luyện để tránh đa cộng tuyến)
workclass ↔ occupation	Khuyết đồng thời ở 1.836 dòng; 7 dòng Never-worked không có nghề	Nhất quán về logic

Kiểm tra	Kết quả	Kết luận
relationship ↔ sex	Husband: 13.192 nam, 1 nữ; Wife: 1.566 nữ, 2 nam	Gần như nhất quán, có 3 bản ghi nghi vấn (1 Husband là nữ, 2 Wife là nam) cần kiểm tra lại, có thể do lỗi nhập hoặc trường hợp hôn nhân đồng giới được mã hóa theo quy ước cũ
Khoảng trắng, định dạng chuỗi	Không có khoảng trắng thừa	Đạt
Miền giá trị	age từ 17 đến 90; hours.per.week từ 1 đến 99; education.num từ 1 đến 16	Nằm trong miền hợp lý

2.6. Phân phối, giá trị bất thường và vấn đề chất lượng khác

- capital.gain và capital.loss lệch rất mạnh (skewness 11,95 và 4,59) và chứa nhiều số 0: 91,67% quan sát có capital.gain = 0 và 95,33% có capital.loss = 0. Cần xem xét biến đổi (log1p) hoặc tạo biến nhị phân "có phát sinh lãi/lỗ vốn".
- Giá trị bị chặn trên (top-coded): 159 quan sát có capital.gain = 99.999 (đây là mã chặn trên chứ không phải số tiền thực); 43 quan sát có age = 90 (tuổi từ 90 trở lên được gộp về 90).
- hours.per.week: 85 quan sát làm đúng 99 giờ/tuần và 145 quan sát làm dưới 5 giờ/tuần. Quy tắc IQR đánh dấu tới 9.008 điểm ngoại lai ở cột này vì phần lớn người làm đúng 40 giờ khiến khoảng tứ phân vị rất hẹp; do đó nên đánh giá ngoại lai theo ý nghĩa nghiệp vụ thay vì chỉ theo IQR.
- Ngoại lai theo quy tắc IQR (1,5 × IQR) ở các cột khác: age 143, fnlwgt 992, capital.gain 2.712, capital.loss 1.519 quan sát.
- fnlwgt lệch phải (skewness 1,45), giá trị tối đa 1.484.705 gấp khoảng 8 lần trung bình; đây là trọng số điều tra, không nên dùng trực tiếp như đặc trưng dự đoán thông thường.
- Mất cân bằng nhóm: race = White chiếm 85,43% (27.816 dòng); native.country = United-States chiếm 89,59%; nam giới chiếm 66,92% (21.790 dòng). Nhóm thiểu số có ít mẫu (ví dụ Amer-Indian-Eskimo 311, Other 271) nên ước lượng cho các nhóm này kém ổn định.
- Chênh lệch thu nhập theo giới: 30,6% nam giới có thu nhập >50K so với 10,9% ở nữ giới, cho thấy rủi ro thiên lệch (bias) nếu dùng sex làm đặc trưng cho mô hình dự đoán.
- Thời điểm dữ liệu: dữ liệu từ năm 1994, ngưỡng 50.000 USD và cơ cấu nghề nghiệp khi đó khác hiện nay; kết quả mô hình chỉ có giá trị minh họa phương pháp, không nên suy rộng cho thực tế hiện tại.

3. Tổng hợp đánh giá và định hướng cho giai đoạn tiếp theo

Vấn đề phát hiện	Mức độ	Hướng xử lý đề xuất
Giá trị khuyết mã hóa bằng "?" (workclass, occupation, native.country; 7,37% dòng)	Cao	Chuyển thành NaN; giữ nhóm Unknown hoặc điền mode; so sánh với phương án bỏ dòng

Vấn đề phát hiện	Mức độ	Hướng xử lý đề xuất
24 dòng trùng lặp	Thấp	Loại bỏ
education và education.num dư thừa	Trung bình	Giữ một cột (ưu tiên education.num)
capital.gain/capital.loss lệch mạnh, nhiều số 0, giá trị chặn 99.999	Cao	Biến đổi log1p hoặc tạo biến nhị phân; xử lý riêng mã 99.999
Ngoại lai ở hours.per.week, age, fnlwgt	Trung bình	Đánh giá theo nghiệp vụ; cân nhắc winsorize
Nhãn income mất cân bằng 76/24	Cao	Phân tầng khi chia tập; dùng F1, ROC-AUC; cân nhắc class weight hoặc SMOTE
3 bản ghi relationship–sex nghi vấn	Thấp	Kiểm tra lại, có thể giữ nguyên
Thuộc tính nhạy cảm (sex, race), biến lệch nhóm	Cao (về đạo đức)	Phân tích công bằng; cân nhắc loại hoặc kiểm soát các biến này
native.country 41 mức	Trung bình	Gộp nhóm (United-States / Mexico / Khác hoặc theo khu vực)

Kết luận: bộ dữ liệu có cấu trúc rõ ràng, kiểu dữ liệu nhìn chung phù hợp và nhất quán nội bộ tốt, không có vấn đề về nối bảng. Các vấn đề chất lượng chính cần xử lý ở giai đoạn 2 (làm sạch và tiền xử lý) là: giá trị khuyết ẩn dưới dạng "?", phân phối lệch mạnh của capital.gain/capital.loss, giá trị chặn trên, dòng trùng lặp và mất cân bằng nhãn.

4. Phân tích quy trình kiểm tra dữ liệu

Giai đoạn 1 trả lời một câu hỏi duy nhất: dữ liệu này có đáng tin để xây mô hình không, và nếu chưa thì sai ở đâu? Mười bốn ô lệnh được xếp theo bốn tầng, đi từ khái quát đến chi tiết.

Thứ tự này không ngẫu nhiên mà theo một nguyên tắc phương pháp luận: không thể tìm lỗi khi chưa biết dữ liệu "bình thường" trông như thế nào. Phải nhìn bảng (tầng 2) thì mới thấy dấu ? ở những dòng đầu, từ đó mới nghĩ tới việc đếm riêng ký tự này (tầng 3). Nếu đảo ngược, người phân tích dễ chạy isna(), nhận kết quả 0 và kết luận sai rằng dữ liệu sạch.

Một nguyên tắc nữa xuyên suốt là "đo trước, sửa sau". Giai đoạn 1 chỉ phát hiện và định lượng vấn đề (bao nhiêu, ở đâu, nặng nhẹ ra sao); việc xóa dòng, điền giá trị khuyết, biến đổi phân phối thuộc về giai đoạn 2. Tách như vậy giúp mỗi quyết định xử lý ở giai đoạn sau có số liệu làm căn cứ, thay vì làm theo thói quen.

4.1. Chuẩn bị môi trường và nạp dữ liệu

- Ô 1: Nạp thư viện

```python
# pandas: đọc và xử lý bảng dữ liệu; numpy: cung cấp giá trị NaN (ô khuyết)
import os
import pandas as pd
import numpy as np

# Cho phép hiển thị đầy đủ tất cả các cột khi in bảng
pd.set_option("display.max_columns", None)

print("Phiên bản pandas:", pd.__version__)
```

```
Phiên bản pandas: 2.2.3
```

Dữ liệu là một bảng lớn gồm hơn 32 nghìn dòng, có cả số lẫn chữ, nên cần công cụ chuyên xử lý bảng số liệu. Ô này nạp công cụ đó và công cụ tính toán đi kèm, đồng thời cài đặt để bảng luôn hiện đủ 15 cột, không bị rút gọn. Nó cũng in ra phiên bản công cụ để nếu kết quả khác nhau giữa các máy thì biết nguyên nhân. Đây là bước chuẩn bị, thiếu nó thì các ô sau không chạy được.

- Ô 2: Đưa file vào Colab

```python
# Nạp thư viện os để kiểm tra file có tồn tại hay không
import os

# Tên file mặc định
FILE = "adult.csv"

# Nếu chưa có file trong thư mục làm việc thì hiện hộp thoại upload (chỉ chạy được trên Colab)
if not os.path.exists(FILE):
    try:
        from google.colab import files        # thư viện riêng của Colab
        uploaded = files.upload()             # mở hộp thoại chọn file từ máy tính
        FILE = list(uploaded.keys())[0]       # lấy tên file vừa upload (có thể là 'adult (1).csv')
    except ImportError:
        raise FileNotFoundError("Không tìm thấy adult.csv. Hãy đặt file cùng thư mục với notebook.")

print("Sẽ đọc file:", FILE)
```

Colab chạy trên máy chủ từ xa nên không tự thấy file trên máy tính. Ô này kiểm tra file dữ liệu đã có chưa, nếu chưa thì mở hộp thoại cho người dùng tải lên. Nó còn tự lấy đúng tên file vừa tải, vì nếu tải lần hai thì Colab đổi tên file, giúp notebook chạy được trọn vẹn trên bất kì máy nào.

- Ô 3: Đọc file

```python
# skipinitialspace=True: bỏ khoảng trắng thừa ở đầu mỗi giá trị chuỗi
df = pd.read_csv(FILE, skipinitialspace=True)
print("Đã đọc file thành công")
```

```
Đã đọc file thành công
```

Ô này đọc file dữ liệu và biến nó thành một bảng trong bộ nhớ, để mọi bước sau làm việc trên bảng này. Ô còn yêu cầu bỏ khoảng trắng thừa ở đầu mỗi giá trị chữ, vì nhiều bản của bộ dữ liệu này có khoảng trắng đó và nó khiến cùng một giá trị bị hiểu thành hai giá trị khác nhau. Đây là bước đưa dữ liệu vào để bắt đầu phân tích.

4.2. Nhận diện cấu trúc, kiểu dữ liệu và thống kê mô tả

- Ô 4: Kích thước dữ liệu

```
# df.shape trả về (số dòng, số cột)
print("Kích thước (dòng, cột):", df.shape)
print("Số quan sát (dòng)   :", df.shape[0])
print("Số thuộc tính (cột)  :", df.shape[1])
```

```
Kích thước (dòng, cột): (32561, 15)
Số quan sát (dòng)   : 32561
Số thuộc tính (cột)  : 15
```

Ô này đếm số dòng và số cột của bảng. Kết quả là 32.561 dòng và 15 cột, nghĩa là có 32.561 người được khảo sát, mỗi người được mô tả bằng 15 thông tin, trong đó 14 thông tin dùng để dự đoán và 1 thông tin là thu nhập cần dự đoán. Đây là số liệu mà đề yêu cầu nêu rõ, đồng thời là mốc để so sánh sau khi làm sạch xem đã bỏ đi bao nhiêu dòng.

- Ô 5: Thông tin cột và kiểu dữ liệu

```
# info(): tên cột, số giá trị không-null và kiểu dữ liệu từng cột
# Lúc này giá trị khuyết còn là ký tự '?' nên info() chưa báo thiếu
df.info()
```

Ô này liệt kê từng cột, kiểu dữ liệu của nó (số hay chữ) và số ô có giá trị. Kết quả có 6 cột số và 9 cột chữ, đều đúng với bản chất từng cột. Một điểm cần chú ý: ô báo mọi cột đều đủ 32.561 giá trị, nhưng điều đó chưa chứng minh dữ liệu đầy đủ, vì các ô ghi dấu ? vẫn bị máy tính tính là có giá trị. Lệnh này dùng để xác nhận kiểu dữ liệu hợp lý, đồng thời tạo tiền đề cho việc phát hiện giá trị thiếu ở Ô 8.

- Ô 6: Xem 5 dòng đầu

```
df.head()
```

Ô này hiện năm dòng đầu của bảng để nhìn bằng mắt xem dữ liệu trông như thế nào. Ngay dòng đầu tiên đã thấy hai cột workclass và occupation ghi dấu ?, đó là dấu hiệu cho thấy dữ liệu dùng ? để đánh dấu chỗ thiếu. Tuy nhiên năm dòng này đều là nữ giới và có đặc điểm khá giống nhau, nên không đại diện cho toàn bộ dữ liệu. Lệnh này chỉ để làm quen định dạng và phát hiện bất thường ban đầu, không dùng để rút ra kết luận chung.

- Ô 7: Thống kê mô tả

```
# count, mean, std, min, 25%, median (50%), 75%, max của các cột số
df.describe()
```

Ô này tính cho mỗi cột số các chỉ số: trung bình, độ phân tán, nhỏ nhất, lớn nhất và các mốc phân vị. Cách đọc hiệu quả là so trung bình với trung vị (giá trị ở giữa). Tuổi trung bình 38,6 và trung vị 37, cân đối và hợp lý. Số giờ làm có trung vị 40, và gần một nửa số người làm đúng 40 giờ. Cột lãi vốn có trung vị 0 nhưng trung bình hơn 1.077 và lớn nhất

99.999, cho thấy đa số người không có lãi vốn còn một số ít có số rất lớn. Lệnh này dùng để phát hiện giá trị bất thường và những cột phân phối lệch cần xử lý ở giai đoạn sau.

4.3. Phát hiện và đo lường giá trị khuyết ẩn

Một dữ liệu có ô khuyết thường có hai dạng: khuyết hiện (ô trống, pandas tự nhận là NaN) và khuyết ẩn (ô được điền một ký hiệu thay thế như ?, N/A, -, 999, pandas coi đó là dữ liệu thật). Bộ Adult thuộc dạng thứ hai, và ba ô dưới đây là phần quan trọng nhất của giai đoạn 1.

- Ô 8: Đổi '?' thành NaN và đếm ô khuyết

```
# Trước khi đổi: isna() báo 0 vì '?' chỉ là một chuỗi bình thường
print("Số NaN trước khi đổi:", df.isna().sum().sum())

# Đổi '?' thành NaN và GÁN lại vào df để các bước sau dùng dữ liệu đã đổi
df = df.replace("?", np.nan)

# Đếm số ô khuyết của từng cột
print("\nSố ô khuyết theo cột:")
print(df.isna().sum())
```

Máy tính chỉ coi một ô là thiếu khi nó thực sự trống, còn bộ dữ liệu này ghi dấu ? vào chỗ thiếu nên lúc đầu máy báo không thiếu ô nào. Ô này chứng minh điều đó bằng kết quả 0, sau đó đổi mọi dấu ? thành ký hiệu "trống" mà máy hiểu, rồi đếm lại. Kết quả: workclass thiếu 1.836 ô, occupation thiếu 1.843 ô, native.country thiếu 583 ô. Đây là bước quan trọng nhất của giai đoạn 1, vì nếu bỏ qua thì dấu ? sẽ bị coi như một nghề nghiệp thật và làm sai lệch mô hình.

- Ô 9: Bảng tỷ lệ khuyết

```
missing = pd.DataFrame({
    "so_o_khuyet": df.isna().sum(),
    "ty_le_%": (df.isna().mean() * 100).round(2),
    "kieu_du_lieu": df.dtypes.astype(str),
}).sort_values("so_o_khuyet", ascending=False)

missing
```

Ô này gom số ô thiếu, phần trăm thiếu và kiểu dữ liệu của từng cột vào một bảng, sắp cột thiếu nhiều nhất lên đầu. Kết quả: occupation thiếu 5,66%, workclass thiếu 5,64%, native.country thiếu 1,79%, 12 cột còn lại không thiếu. Tính chung, 4.262 ô thiếu trên tổng 488.415 ô, chỉ khoảng 0,87%. Mức thiếu nhỏ nên không làm mẫu mất tính đại diện, nhưng con số nhỏ chưa đủ để kết luận việc thiếu là vô hại.

- Ô 10: Tổng quan khuyết

```
so_dong_khuyet = int(df.isna().any(axis=1).sum())
print("Số cột có khuyết       :", int((df.isna().sum() > 0).sum()), "/", df.shape[1])
print("Tổng số ô khuyết       :", int(df.isna().sum().sum()))
print("Số dòng có >= 1 ô khuyết:", so_dong_khuyet, f"({so_dong_khuyet / len(df) * 100:.2f}%)")
```

Các ô trước đếm theo cột, còn ô này đếm theo dòng để trả lời câu hỏi: nếu bỏ hết các dòng có ô thiếu thì mất bao nhiêu dữ liệu. Kết quả là 2.399 dòng (7,37%), ít hơn 4.262 vì một dòng thường thiếu nhiều ô cùng lúc, điển hình là thiếu cả nơi làm việc lẫn nghề nghiệp. Ô này cũng cho thấy có 7 người chưa từng đi làm nên không có nghề, rất hợp lý. Việc thiếu thông tin có quy luật chứ không ngẫu nhiên, nên không nên tự ý điền bằng giá trị phổ biến nhất.

4.4. Dòng trùng lặp, biến mục tiêu và nhất quán logic

- Ô 11: Dòng trùng lặp

```
so_trung = int(df.duplicated().sum())
print("Số dòng trùng lặp:", so_trung, f"({so_trung / len(df) * 100:.2f}%)")
```

Ô này đếm số dòng giống hệt một dòng đã xuất hiện trước đó. Có 24 dòng như vậy, chiếm 0,07%. Dòng trùng khiến một người bị tính nhiều lần, và nếu bản sao lọt vào cả tập huấn luyện lẫn tập kiểm tra thì mô hình như được "xem trước đáp án", làm điểm đánh giá cao ảo. Vì dữ liệu không có mã định danh từng người nên chưa chắc đó là bản sao hay hai người giống hệt nhau. Lệnh trên chỉ phát hiện và đếm ở giai đoạn này, việc xóa để giai đoạn sau.

- Ô 12: Phân bố biến mục tiêu income

```
print(df["income"].value_counts(normalize=True))

pd.DataFrame({
    "so_luong": df["income"].value_counts(),
    "ty_le_%": (df["income"].value_counts(normalize=True) * 100).round(2),
})
```

Thu nhập là điều mô hình phải dự đoán nên cần biết nó phân bố ra sao. Kết quả: nhóm không quá 50K chiếm 75,92%, nhóm trên 50K chiếm 24,08%, tức lệch khoảng 3 trên 1. Điều này có nghĩa là một mô hình lúc nào cũng đoán "không quá 50K" đã đúng gần 76% mà không học được gì cả. Không thể chỉ dùng tỷ lệ đoán đúng để đánh giá mô hình, mà phải dùng thêm các thước đo khác và chia dữ liệu sao cho hai tập đều giữ tỷ lệ 76/24.

- Ô 13: Kiểm tra logic Nam/Nữ

```
# Kỳ vọng: Husband gần như toàn Male, Wife gần như toàn Female
pd.crosstab(df["relationship"], df["sex"])
```

Dữ liệu chỉ có một file nên không có cách kiểm tra khớp giữa các file, ô này thay bằng kiểm tra khớp giữa hai cột có quan hệ ràng buộc là vai trò trong gia đình và giới tính, vì chồng phải là nam còn vợ phải là nữ. Kết quả phần lớn khớp (13.192 nam là chồng, 1.566 nữ là vợ), nhưng có 3 trường hợp mâu thuẫn: 1 người là chồng nhưng là nữ, 2 người là vợ nhưng là nam. Có thể là lỗi nhập hoặc cách ghi theo quy ước cũ. Lệnh cho thấy lỗi chỉ lộ ra khi đối chiếu hai cột với nhau, và vì chỉ có 3 trường hợp trên hơn 32 nghìn dòng nên ảnh hưởng rất nhỏ.

- Ô 14: Tổng hợp tự động

```
so_cot_so = df.select_dtypes(include="number").shape[1]
print(f"- Quy mô: {df.shape[0]:,} dòng x {df.shape[1]} cột ({so_cot_so} cột số, {df.shape[1] - so_cot_so} cột chuỗi).")
for ten_cot, hang in missing[missing["so_o_khuyet"] > 0].iterrows():
    print(f"- Cột '{ten_cot}' khuyết {int(hang['so_o_khuyet']):,} ô ({hang['ty_le_%']}%).")
print(f"- {so_dong_khuyet:,} dòng có ít nhất một ô khuyết.")
print(f"- Dòng trùng lặp: {so_trung}.")
print("\nHOÀN TẤT: notebook đã chạy xong không lỗi.")
```

Ô cuối tự gom các kết quả đã tính ở trên thành bản tóm tắt: 32.561 dòng và 15 cột, ba cột bị thiếu dữ liệu với tỷ lệ lần lượt 5,66%, 5,64% và 1,79%, có 2.399 dòng thiếu ít nhất một ô và 24 dòng trùng lặp. Việc để máy tự điền con số từ kết quả thật giúp bản tóm tắt luôn khớp với dữ liệu, không sai sót do gõ tay. Dòng "HOÀN TẤT" ở cuối cho biết toàn bộ notebook đã chạy xong không lỗi. Lệnh này giúp người chấm một cái nhìn tổng quát ngay trong notebook mà không phải tự ghép từ nhiều ô.

B. Giai đoạn 2: Tiền xử lý và làm sạch dữ liệu

1. Tổng quan giai đoạn 2:

Ở giai đoạn 1, nhóm đã thu thập và đánh giá dữ liệu ban đầu của bộ dữ liệu, từ đó xác định các kiểu dữ liệu, vị trí ô khuyết và những điểm bất thường cần lưu ý. Giai đoạn 2 tiếp nối kết quả đó, với mục tiêu đưa dữ liệu về trạng thái sạch và nhất quán trước khi phân tích các yếu tố quyết định mức thu nhập trên hay dưới 50.000 USD/năm.

Giai đoạn này gồm hai nhiệm vụ. Thứ nhất là xử lý bất thường: đưa ra minh chứng rõ ràng cho các vấn đề về sai định dạng, dữ liệu trùng lặp và ngoại lệ bằng biểu đồ và các phép tính. Thứ hai là giải trình lựa chọn kỹ thuật: với mỗi bước, nhóm không chỉ trình bày kết quả mà còn nêu lý do chọn giải pháp dựa trên chính phân phối của dữ liệu, ví dụ vì sao điền nhãn "Unknown" thay vì điền giá trị phổ biến nhất, khi nào dùng median thay vì mean, vì sao dùng one-hot thay vì label encoding, và vì sao chọn StandardScaler thay vì MinMaxScaler hay RobustScaler.

2. Giai đoạn tiền xử lí và làm sạch dữ liệu:

2.1. Chuẩn bị môi trường và kiểm tra chất lượng dữ liệu:

Đây là giai đoạn giúp nhóm chuẩn bị các thư viện cần thiết, đổi tên cột cho dễ thao tác, đồng thời kiểm tra toàn diện chất lượng dữ liệu thông qua bảng thống kê, biểu đồ nhiệt giá trị thiếu và phân tích độ lệch của các biến số.

- Ô 14: Chuẩn bị thư viện và chuẩn hóa tên cột

```
import matplotlib.pyplot as plt                          # vẽ biểu đồ cơ bản
import seaborn as sns                                    # vẽ heatmap, boxplot, histogram
from IPython.display import display                      # hiển thị nhiều bảng trong 1 cell
from sklearn.model_selection import train_test_split     # chia tập train/test
from sklearn.preprocessing import StandardScaler         # chuẩn hóa z-score

sns.set_theme(style="whitegrid")

df_before = df.copy()   # lưu bản trước khi làm sạch để so sánh ở cuối

# Đổi dấu chấm trong tên cột thành gạch dưới ("education.num" -> "education_num")
df.columns = df.columns.str.replace(".", "_", regex=False)
print("Tên cột sau khi đổi:", df.columns.tolist())
```

Ô đầu tiên của giai đoạn tiền xử lý nạp các thư viện phục vụ vẽ biểu đồ, hiển thị bảng, chia tập dữ liệu và chuẩn hóa. Đồng thời, ô này lưu một bản sao của dữ liệu gốc để so sánh trước và sau khi làm sạch, và đổi tên các cột từ dạng có dấu chấm sang dấu gạch dưới. Tên cột sau khi đổi có thể được gọi trực tiếp bằng cú pháp thuộc tính của pandas mà không gây lỗi, còn bản sao dữ liệu gốc cho phép đối chiếu kết quả ở cuối giai đoạn.

Nhóm dùng df_before = df.copy() để giữ nguyên trạng thái ban đầu của dữ liệu. Nếu chỉ gán df_before = df thì hai biến cùng trỏ đến một bảng và mọi thay đổi sau đó đều ảnh hưởng đến cả hai, nên phải tạo bản sao độc lập thì bảng tổng kết ở ô cuối mới so sánh được đúng trước và sau. Với tên cột, nhóm dùng str.replace(".", "_") vì dấu chấm khiến cột như education.num không thể truy cập bằng df.education.num (pandas hiểu education là một cột rồi tìm thuộc tính num của nó), và cũng gây khó khăn khi dùng tên cột trong các công thức.

- Ô 15: Kiểm toán chất lượng dữ liệu

```
cat_cols = df.select_dtypes(include=["object", "string"]).columns.tolist()   # các cột chữ

audit = pd.DataFrame({
    "dtype": df.dtypes.astype(str),                    # kiểu dữ liệu
    "so_gia_tri_khac_nhau": df.nunique(),              # số giá trị phân biệt
    "so_o_thieu": df.isna().sum(),                     # số ô NaN
    "khoang_trang_thua": [                             # ô có khoảng trắng thừa (chỉ cột chữ)
        (df[c].dropna() != df[c].dropna().str.strip()).sum() if c in cat_cols else 0
        for c in df.columns
    ],
})
display(audit)
print("\nCác giá trị của income:", df["income"].unique())   # phải đúng 2 nhãn
```

Ô này tạo một bảng tổng hợp kiểm tra toàn bộ các cột về bốn mặt: kiểu dữ liệu, số giá trị phân biệt, số ô thiếu và số ô có khoảng trắng thừa.

Sau khi thay ký tự "?" bằng NaN, ô này rà soát xem dữ liệu còn lỗi định dạng nào khác hay không, đồng thời cho biết số ô thiếu thật của từng cột (1.836 ở workclass, 1.843 ở occupation, 583 ở native_country) và in các giá trị của income để xác nhận cột này chỉ có hai nhãn <=50K và >50K.

Nhóm dùng select_dtypes với cả hai kiểu "object" và "string" để tự nhận diện các cột chữ, nhờ vậy code chạy đúng trên cả pandas phiên bản cũ lẫn mới và vẫn đúng khi dataset có thêm cột. Khoảng trắng thừa được phát hiện bằng cách so sánh từng giá trị với chính nó sau khi gọi .str.strip(), vì đây là lỗi dễ bị bỏ sót: "Private" và "Private " (thừa một dấu cách) trông giống nhau nhưng máy coi là hai nhóm khác nhau, làm sai các phép đếm và mã hóa về sau. Nhóm gọi .dropna() trước phép so sánh vì NaN không bằng bất kỳ giá trị nào, kể cả chính nó, nên nếu không loại thì các ô thiếu sẽ bị đếm nhầm thành lỗi khoảng trắng. Cuối cùng, nhóm in riêng giá trị của income vì đây là biến mục tiêu: chỉ một nhãn lạ hoặc biến thể như "<=50K." cũng đủ làm sai bước huấn luyện và đánh giá mô hình, nên cần xác nhận trước khi đi tiếp.

- Ô 16: Minh chứng giá trị thiếu bằng heatmap

```
plt.figure(figsize=(12, 5))
sns.heatmap(df.isna(), cbar=False, cmap="viridis", yticklabels=False)
plt.title("Bản đồ nhiệt các ô thiếu (vạch sáng = thiếu)")
plt.show()
```

Ô này vẽ một bản đồ nhiệt thể hiện vị trí các ô thiếu trong toàn bộ dữ liệu: mỗi hàng ngang là một người, mỗi cột là một thuộc tính, và ô thiếu hiện thành vạch sáng trên nền tối. Biểu đồ cho thấy vạch sáng chỉ xuất hiện ở ba cột workclass, occupation và native_country, trong đó hai cột đầu thiếu trên cùng các dòng.

Nhóm chọn heatmap vì đây là cách nhanh nhất để thấy vị trí thiếu và việc các cột có thiếu cùng nhau hay không. Tham số cbar=False tắt thanh màu vì biểu đồ chỉ có hai trạng thái (có giá trị và thiếu), và tiêu đề đã ghi rõ "vạch sáng = thiếu". Tham số yticklabels=False tắt nhãn dòng vì hơn 32 nghìn nhãn sẽ chồng thành một khối đen không đọc được. Bảng màu viridis có độ tương phản cao giữa nền tối và vạch vàng nên dễ phân biệt. Ô này phải chạy trước bước điền giá trị thiếu, vì sau đó biểu đồ chỉ còn nền tối.

- Ô 17: Phân tích mối quan hệ giữa các giá trị thiếu

```
# workclass và occupation có thiếu cùng nhau không?
display(pd.crosstab(df["workclass"].isna(), df["occupation"].isna(),
                    rownames=["workclass thiếu?"], colnames=["occupation thiếu?"]))

# Tỷ lệ thu nhập >50K: nhóm có ô thiếu so với nhóm đủ thông tin
co_o_thieu = df.isna().any(axis=1)
ty_le_50k = df.groupby(co_o_thieu)["income"].apply(lambda s: (s == ">50K").mean())
ty_le_50k = ty_le_50k.rename({False: "Đủ thông tin", True: "Có ô thiếu"})
print("Tỷ lệ thu nhập >50K theo nhóm:")
print((ty_le_50k * 100).round(1).astype(str) + " %")
```

Ô này làm hai việc: kiểm tra workclass và occupation có thiếu đồng thời hay không bằng bảng chéo (crosstab), và so sánh tỷ lệ thu nhập trên 50K giữa nhóm có ít nhất một ô thiếu với nhóm đủ thông tin. Bảng chéo cho thấy 1.836 dòng thiếu cả hai cột, 7 dòng chỉ thiếu occupation (đều là Never-worked), không dòng nào chỉ thiếu workclass và 30.718 dòng đủ cả hai, nên hai cột thiếu gần như luôn đi cùng nhau. Nhóm có ô thiếu chỉ có 13,9% người trên 50K so với 24,9% ở nhóm đủ thông tin, tức dữ liệu thiếu không ngẫu nhiên.

Nhóm dùng crosstab vì bảng chéo cho thấy cùng lúc mọi tổ hợp (thiếu cả hai, thiếu một cột, không thiếu). Với phép so sánh, df.isna().any(axis=1) tạo ra một cột đúng/sai cho biết mỗi dòng có ít nhất một ô thiếu hay không, groupby chia dữ liệu thành hai nhóm theo cột này, và apply tính tỷ lệ dòng có income là >50K trong mỗi nhóm (trung bình của một dãy đúng/sai chính là tỷ lệ phần trăm số dòng đúng). Phần rename và định dạng phần trăm chỉ để kết quả dễ đọc. Phép so sánh này quyết định cách xử lý: nếu thiếu ngẫu nhiên thì hai nhóm sẽ có tỷ lệ xấp xỉ nhau, nhưng khi khác biệt rõ thì cả hai cách thông thường đều có vấn đề. Xóa dòng thiếu sẽ loại đúng một nhóm có đặc điểm thu nhập riêng và làm lệch mẫu, còn điền

mode sẽ gán sai nhóm cho hàng nghìn người và xóa mất tín hiệu "không khai báo". Vì vậy nhóm chọn điền nhãn riêng Unknown cho hai cột nghề, để giữ nguyên dòng và giữ lại thông tin. Ô này phải chạy trước bước điền giá trị thiếu, vì sau đó không còn ô thiếu để so sánh.

- Ô 18: Phân tích độ lệch của biến số

```
num_cols = ["age", "fnlwgt", "education_num", "capital_gain", "capital_loss", "hours_per_week"]
so_sanh = pd.DataFrame({
    "mean": df[num_cols].mean(),
    "median": df[num_cols].median(),
    "skew": df[num_cols].skew(),                    # skew > 1: lệch phải mạnh
}).round(2)
so_sanh["mean_tru_median"] = (so_sanh["mean"] - so_sanh["median"]).round(2)
display(so_sanh)
```

Ô này lập một bảng so sánh mean, median và hệ số lệch (skewness) của sáu biến số, kèm cột cho biết mean lớn hơn median bao nhiêu, nhằm đánh giá mức độ lệch phân phối của từng biến.

Bảng giúp xác định biến nào lệch mạnh để quyết định có cần biến đổi log hay không. Trên dữ liệu của nhóm, capital_gain lệch phải rất mạnh (skewness 11,95, mean 1.078 so với median 0), capital_loss cũng mạnh (4,59, mean 87,3 so với median 0) và fnlwgt lệch rõ (1,45, mean 189.778 so với median 178.356), còn age (0,56), education_num (−0,31) và hours_per_week (0,23) gần đối xứng. Bảng cũng minh chứng cho nguyên tắc chọn median thay mean: ở cột lệch phải, mean bị một số ít giá trị lớn kéo lên nên không đại diện cho người điển hình. Dataset không có ô thiếu ở cột số nên nguyên tắc này chỉ là minh chứng, không dùng để điền giá trị.

Nhóm đặt mean và median cạnh nhau vì chênh lệch giữa chúng là chỉ báo nhanh: khi mean lớn hơn median rõ rệt, phân phối thường có đuôi kéo dài về phía giá trị lớn. Hiệu mean − median phụ thuộc đơn vị của từng cột nên chỉ đọc được trong từng cột, vì vậy nhóm dùng thêm skewness (không phụ thuộc đơn vị, so sánh được giữa các biến) với ngưỡng lớn hơn 1 là quy ước kinh nghiệm cho lệch phải mạnh. Ba biến vượt ngưỡng (fnlwgt, capital_gain, capital_loss) được biến đổi log1p ở bước sau, vì log nén đuôi phải và log1p xử lý được giá trị 0 rất phổ biến ở hai cột capital.

2.2. Xử lý giá trị thiếu:

- Ô 19: Xử lý giá trị thiếu

```
for col in ["workclass", "occupation"]:
    df[col] = df[col].fillna("Unknown")              # nhãn riêng cho nhóm không khai báo

mode_country = df["native_country"].mode()[0]        # giá trị xuất hiện nhiều nhất
df["native_country"] = df["native_country"].fillna(mode_country)

print("Mode của native_country:", mode_country)
print("Tổng số ô thiếu còn lại:", df.isna().sum().sum())   # kỳ vọng = 0
```

Ô này điền giá trị cho ba cột bị thiếu là workclass, occupation và native_country: hai cột đầu được điền nhãn "Unknown", cột còn lại được điền giá trị xuất hiện nhiều nhất (United-States). Sau ô này dữ liệu không còn ô trống nào (dòng in cuối cho kết quả 0), nên sẵn sàng cho bước mã hóa và huấn luyện mô hình, vì hầu hết mô hình không chấp nhận giá trị NaN.

Về lựa chọn phép điền: cả ba cột bị khuyết đều là biến phân loại nên không thể dùng mean hay median (chỉ dùng cho dữ liệu số). Với native.country, nhóm dùng mode vì chỉ khuyết 1,8% và một nhóm áp đảo (khoảng 91%). Với workclass và occupation, nhóm dùng nhãn riêng "Unknown" thay vì mode vì dữ liệu khuyết không ngẫu nhiên (nhóm khuyết có tỷ lệ thu nhập >50K là 13,9%, so với 24,9% ở nhóm đủ thông tin).

Dataset không có ô khuyết ở cột số. Nếu có, nhóm sẽ dùng median thay vì mean cho các cột lệch mạnh, vì mean bị giá trị cực lớn kéo lệch. Ví dụ capital.gain có mean 1.078 nhưng median 0 (độ lệch skewness 11,95), nên điền mean sẽ tạo ra mức lãi vốn mà gần như không ai có.

2.3. Xử lý dữ liệu trùng lặp:

- Ô 20: Kiểm tra dữ liệu trùng lặp

```
so_trung = df.duplicated().sum()
print("Số dòng trùng:", so_trung)

# keep=False: hiện cả bản gốc lẫn bản sao, sắp xếp để các cặp nằm cạnh nhau
dong_trung = df[df.duplicated(keep=False)].sort_values(list(df.columns))
display(dong_trung.head(6))

# Đối chứng: nếu bỏ fnlwgt thì số dòng trùng là bao nhiêu?
print("Số giá trị fnlwgt khác nhau:", df["fnlwgt"].nunique(), "/", len(df), "dòng")
print("Số dòng trùng nếu bỏ fnlwgt :", df.drop(columns="fnlwgt").duplicated().sum())
print("Số dòng trùng nếu giữ fnlwgt:", so_trung)
```

Ô này đếm số dòng trùng hoàn toàn, in ra một số cặp dòng trùng để minh chứng, rồi so sánh số dòng trùng khi giữ và khi bỏ cột fnlwgt. Ô này xác nhận có 24 dòng trùng (khoảng 0,07%) và cung cấp bằng chứng để kết luận đó là bản sao thật trước khi quyết định xóa. Vì dataset không có cột ID, không thể khẳng định trực tiếp đó là cùng một người, nên cần phép đối chứng với fnlwgt.

Nhóm dùng keep=False để hiện cả bản gốc lẫn bản sao, và sort_values theo tất cả các cột để các cặp trùng nằm cạnh nhau, giúp quan sát bằng mắt dễ hơn. Phép đối chứng dựa trên tính chất của fnlwgt: cột này có 21.648 giá trị khác nhau trên 32.561 dòng, tức gần như duy nhất cho mỗi người. Khi bỏ fnlwgt, số dòng trùng tăng vọt lên 3.533, vì đó là những người khác nhau tình cờ giống nhau về nhân khẩu học. Khi giữ fnlwgt, chỉ còn 24 dòng trùng. Nghĩa là 24 dòng này trùng khớp cả một giá trị gần như không thể trùng ngẫu nhiên, nên gần như chắc chắn là bản sao do lỗi nhập hoặc ghép dữ liệu, không phải hai người thật.

- Ô 21: Xóa dữ liệu trùng lặp

```
truoc = len(df)
df = df.drop_duplicates(keep="first").reset_index(drop=True)   # gán lại, không dùng inplace
print(f"Đã xóa {truoc - len(df)} dòng. Còn lại {len(df)} dòng.")
```

Ô này xóa các dòng trùng hoàn toàn khỏi dữ liệu, giữ lại bản xuất hiện đầu tiên, rồi đánh lại chỉ số dòng. Ô này đảm bảo mỗi quan sát chỉ xuất hiện một lần. Nếu giữ bản sao, một quan sát sẽ bị đếm nhiều lần và có thể rơi vào cả tập train lẫn tập test, khiến mô hình học thiên lệch và kết quả đánh giá lạc quan hơn thực tế. Kết quả in ra cho biết đã xóa 24 dòng, còn lại 32.537 dòng, tức chỉ mất khoảng 0,07% dữ liệu nên không làm đổi phân phối.

Nhóm dùng keep="first" để giữ bản ghi đầu tiên; vì các dòng trùng giống hệt nhau nên giữ bản nào cũng cho kết quả như nhau, chọn "first" chỉ để hành vi xác định và dễ lặp lại. Phần reset_index(drop=True) cần thiết vì sau khi xóa, chỉ số dòng bị đứt quãng (thiếu các số của dòng đã xóa); đánh lại chỉ số liên tục giúp các bước sau thao tác ổn định, còn drop=True ngăn chỉ số cũ bị thêm vào bảng thành một cột thừa. Nhóm gán lại df = ... thay vì dùng inplace=True để code rõ ràng và dễ theo dõi, vì nhìn vào là biết df đã bị thay đổi ở dòng nào. Biến truoc lưu số dòng trước khi xóa để dòng cuối in ra được số dòng đã xóa, làm bằng chứng cho báo cáo.

2.4. Phát hiện và phân tích ngoại lệ (Outliers):

- Ô 22: Phát hiện ngoại lệ trên biến age bằng IQR

```
def iqr_bounds(s):
    q1 = s.quantile(0.25)                          # tứ phân vị thứ nhất
    q3 = s.quantile(0.75)                          # tứ phân vị thứ ba
    iqr = q3 - q1                                  # khoảng tứ phân vị
    return q1 - 1.5 * iqr, q3 + 1.5 * iqr          # (ngưỡng dưới, ngưỡng trên)

lower_bound, upper_bound = iqr_bounds(df["age"])
outliers = df[(df["age"] < lower_bound) | (df["age"] > upper_bound)]
print(f"age: ngưỡng [{lower_bound:.1f}, {upper_bound:.1f}] -> {len(outliers)} ngoại lệ ({len(outliers)/len(df):.2%})")
```

Ô này định nghĩa hàm iqr_bounds để tính hai ngưỡng ngoại lệ theo phương pháp IQR, rồi áp dụng lên biến age để đếm số giá trị nằm ngoài hai ngưỡng đó. Ô này minh họa cách làm trên một biến cụ thể trước khi mở rộng ra toàn bộ biến số. Kết quả cho age là ngưỡng từ −2 đến 78, có 142 giá trị ngoại lệ (0,44%). Ngưỡng dưới âm nên không có ai bị coi là ngoại lệ phía dưới; toàn bộ ngoại lệ nằm ở phía trên (trên 78 tuổi), tức là người cao tuổi thật chứ không phải lỗi nhập liệu.

Phương pháp IQR tính khoảng giữa tứ phân vị thứ nhất (Q1) và thứ ba (Q3), rồi coi giá trị nằm ngoài khoảng từ Q1 − 1,5 × IQR đến Q3 + 1,5 × IQR là ngoại lệ. Nhóm chọn phương pháp này vì nó không giả định dữ liệu phân phối chuẩn, nên phù hợp với các biến lệch của bộ dữ liệu, khác với Z-score vốn dựa vào mean và độ lệch chuẩn vốn nhạy với chính các giá trị cực đoan. Việc viết thành hàm iqr_bounds giúp tái sử dụng ở ô sau cho cả sáu biến số mà không lặp lại code. Dòng print in cả hai ngưỡng, số lượng và tỷ lệ phần trăm ngoại lệ để người đọc hình dung ngay mức độ nghiêm trọng, vì con số tuyệt đối (142) khó đánh giá nếu không biết nó chiếm bao nhiêu trên tổng số dòng.

- Ô 23: Tổng hợp ngoại lệ của tất cả biến số

```
dong = []
for c in num_cols:
    lo, hi = iqr_bounds(df[c])
    so_ngoai_le = int(((df[c] < lo) | (df[c] > hi)).sum())
    dong.append({"cot": c, "min": df[c].min(), "max": df[c].max(),
                 "nguong_duoi": lo, "nguong_tren": hi,
                 "so_ngoai_le": so_ngoai_le, "ty_le_%": 100 * so_ngoai_le / len(df),
                 "skew": df[c].skew()})
bang_iqr = pd.DataFrame(dong).set_index("cot").round(2)
display(bang_iqr)
```

Ô này áp dụng hàm iqr_bounds cho cả sáu biến số và gom kết quả vào một bảng gồm giá trị nhỏ nhất, lớn nhất, hai ngưỡng IQR, số lượng và tỷ lệ ngoại lệ, cùng hệ số lệch. Kết quả cho thấy hai nhóm bất thường. Capital_gain và capital_loss có cả hai ngưỡng bằng 0 (hơn 90% giá trị bằng 0 nên Q1 = Q3 = 0, IQR bằng 0), nên mọi giá trị khác 0 đều bị gắn nhãn ngoại lệ (2.712 và 1.519 dòng). Hours_per_week có ngưỡng rất hẹp (32,5 đến 52,5) vì gần một nửa số người làm đúng 40 giờ, nên 27,67% bị gắn nhãn ngoại lệ. Các biến còn lại có tỷ lệ thấp và hợp lý: age 0,44%, fnlwgt 3,05%, education_num 3,67%.

Nhóm dùng vòng lặp qua num_cols để mọi biến được xử lý bằng cùng một quy tắc, rồi gom kết quả vào một DataFrame để hiển thị gọn và đưa thẳng vào báo cáo. Bảng kết hợp min, max, ngưỡng, số ngoại lệ và skew trong cùng một nơi vì từng thông tin riêng lẻ dễ gây hiểu lầm: số ngoại lệ lớn chưa chắc là vấn đề nếu chỉ do ngưỡng hẹp, skew cho biết hình dạng phân phối, còn min và max cho biết giá trị cực đoan có nằm trong miền hợp lệ hay không. Tỷ lệ phần trăm được tính trên tổng số dòng để so sánh được giữa các biến.

- Ô 24: Minh chứng ngoại lệ bằng biểu đồ

```
fig, axes = plt.subplots(2, len(num_cols), figsize=(22, 7))
for i, c in enumerate(num_cols):
    sns.boxplot(y=df[c], ax=axes[0, i], color="lightsteelblue")
    axes[0, i].set_title(f"{c}\nskew = {df[c].skew():.2f}")
    sns.histplot(df[c], bins=40, ax=axes[1, i], color="steelblue")
plt.tight_layout()
plt.show()
```

Ô này vẽ cho mỗi biến số hai biểu đồ xếp dọc, boxplot ở hàng trên và histogram ở hàng dưới, để nhìn trực quan hình dạng phân phối và các giá trị ngoại lệ. Trên dữ liệu của nhóm, boxplot của capital_gain và capital_loss chỉ là một đường phẳng ở 0 kèm các chấm rời rạc phía trên (lên tới 99.999 ở capital_gain), phản ánh việc hơn 90% giá trị bằng 0. Histogram của hours_per_week có một cột rất cao tại 40 giờ, fnlwgt có đuôi phải kéo dài, age chỉ có ngoại lệ ở phía trên, còn education_num có ngoại lệ ở phía dưới (nhóm học vấn thấp).

Nhóm kết hợp hai loại biểu đồ vì chúng bổ sung cho nhau: boxplot cho thấy điểm nào bị coi là ngoại lệ theo cùng quy tắc 1,5 × IQR với bảng ở ô trước nên hai kết quả khớp nhau, còn histogram cho thấy hình dạng toàn bộ phân phối (đỉnh, đuôi, khối số 0) mà boxplot không

thể hiện. Đặt chung trong một hình, mỗi biến một cột, giúp so sánh các biến cạnh nhau, và tiêu đề ghi kèm skewness để đối chiếu với bảng ở ô 18

- Ô 25: Phân tích các giá trị đặc biệt

```
cg = df["capital_gain"]
nhom_99999 = df[cg == 99999]
print("capital_gain = 0     :", f"{(cg == 0).mean():.1%} số dòng")
print("capital_gain = 99999 :", len(nhom_99999), "dòng; tỷ lệ >50K:", f"{(nhom_99999['income'] == '>50K').mean():.0%}")
print("hours_per_week = 40  :", f"{(df['hours_per_week'] == 40).mean():.1%} số dòng")
print("hours_per_week >= 80 :", (df["hours_per_week"] >= 80).sum(), "dòng")
print("age = 90             :", (df["age"] == 90).sum(), "dòng")
```

Ô này kiểm tra các giá trị cực đoan: nhóm capital_gain bằng 0 và bằng 99.999, nhóm làm đúng 40 giờ và từ 80 giờ trở lên mỗi tuần, và nhóm đúng 90 tuổi. Quy tắc IQR chỉ cho biết một giá trị là hiếm, chưa cho biết đó là lỗi hay dữ liệu thật, nên ô này đối chiếu từng giá trị bất thường với dữ liệu để quyết định giữ hay xử lý. Kết quả: 91,7% dòng có capital_gain bằng 0 nên IQR không phù hợp với cột này; 159 dòng bằng 99.999 và 100% trong nhóm đó có thu nhập trên 50K; 46,7% người làm đúng 40 giờ nên ngưỡng IQR của hours_per_week rất hẹp; 341 người làm từ 80 giờ trở lên; và 42 người đúng 90 tuổi.

Nhóm tính riêng tỷ lệ thu nhập của nhóm 99.999 vì giá trị này nhiều khả năng là mã chặn trên (“từ 99.999 trở lên”) chứ không phải số tiền thật. Khi 100% nhóm này có thu nhập cao, đây là tín hiệu rất mạnh về biến mục tiêu, nên xóa hay thay bằng giá trị khác đều làm mất thông tin quan trọng. Với hours_per_week và age, các nhóm cực đoan (341 và 42 người) chỉ chiếm phần rất nhỏ trong hơn 32 nghìn dòng và nằm trong miền hợp lệ, nên nhóm quyết định giữ nguyên ngoại lệ thay vì loại bỏ.

2.5. Biến đổi dữ liệu để giảm độ lệch:

- Ô 26: Biến đổi dữ liệu giảm độ lệch

```
df["capital_gain_capped"] = (df["capital_gain"] == 99999).astype(int)   # 1 nếu bị chặn trên
df["has_capital_gain"] = (df["capital_gain"] > 0).astype(int)
df["has_capital_loss"] = (df["capital_loss"] > 0).astype(int)
for c in ["fnlwgt", "capital_gain", "capital_loss"]:
    df[c + "_log"] = np.log1p(df[c])                    # log(1 + x), dùng được khi x = 0

fig, axes = plt.subplots(2, 3, figsize=(15, 6))
for i, c in enumerate(["fnlwgt", "capital_gain", "capital_loss"]):
    sns.histplot(df[c], bins=40, ax=axes[0, i], color="tab:red")
    axes[0, i].set_title(f"{c} (trước) skew = {df[c].skew():.2f}")
    sns.histplot(df[c + "_log"], bins=40, ax=axes[1, i], color="tab:green")
    axes[1, i].set_title(f"{c}_log (sau) skew = {df[c + '_log'].skew():.2f}")
plt.tight_layout()
plt.show()
```

Ô này tạo ba biến nhị phân để giữ thông tin về vốn (capital_gain_capped cho biết giá trị bị chặn ở 99.999, has_capital_gain và has_capital_loss cho biết có hay không có lãi hoặc lỗ vốn), rồi áp dụng log1p cho ba biến lệch mạnh là fnlwgt, capital_gain và capital_loss. Cuối ô, histogram vẽ phân phối của ba biến trước (màu đỏ) và sau (màu xanh) khi biến đổi, kèm skewness trên tiêu đề. Ô này giảm độ lệch mà không xóa dòng nào, giúp các mô hình nhạy với phân phối như hồi quy logistic hoạt động ổn định hơn. Skewness của capital_gain giảm từ

11,95 xuống 3,09, capital_loss từ 4,59 xuống 4,31 và fnlwgt từ 1,45 xuống −0,84; riêng capital_loss chỉ giảm nhẹ vì hơn 90% giá trị là 0 nên khối số 0 vẫn còn sau khi lấy log.

Nhóm không xóa ngoại lệ vì chúng là giá trị thật và mang thông tin, đặc biệt nhóm capital_gain bằng 99.999 có 100% thu nhập trên 50K. Nhóm chọn log1p, tức log của (1 + x), thay vì log thông thường vì hai cột capital chứa rất nhiều giá trị 0, mà log của 0 không xác định; cộng thêm 1 giúp tính được cả giá trị 0 và vẫn nén đuôi phải. Ba biến nhị phân bù cho phần thông tin mà log không giữ được: capital_gain_capped giữ lại việc giá trị bị cắt đỉnh (sau log, 99.999 chỉ còn là một số lớn bình thường), còn has_capital_gain và has_capital_loss giữ thông tin "có hay không" mà khối số 0 làm lu mờ.

2.6. Loại bỏ cột dư thừa và lưu bản sạch:

- Ô 27: Loại bỏ cột dư thừa và lưu bản sạch

```
print("education -> education_num tối đa", df.groupby("education")["education_num"].nunique().max(), "giá trị
print("education_num -> education tối đa", df.groupby("education_num")["education"].nunique().max(), "giá trị
# Cả hai = 1 nghĩa là hai cột chứa cùng thông tin -> bỏ cột chữ, giữ cột số
df = df.drop(columns="education")

df.to_csv("adult_clean.csv", index=False)
print("Kích thước bản sạch:", df.shape)
```

Ô này kiểm tra xem hai cột education (dạng chữ) và education_num (dạng số) có chứa cùng một thông tin hay không, rồi bỏ cột chữ và lưu dữ liệu đã làm sạch (chưa mã hóa) thành file adult_clean.csv để các thành viên khác dùng trực tiếp mà không phải chạy lại quy trình. Hai dòng kiểm tra đầu đều in ra 1, nghĩa là mỗi giá trị education ứng với đúng một giá trị education_num và ngược lại (16 mức), tức hai cột ánh xạ một-một.

Nhóm kiểm tra bằng groupby().nunique().max() theo cả hai chiều: gom dữ liệu theo từng giá trị của một cột, đếm số giá trị khác nhau của cột kia trong mỗi nhóm rồi lấy giá trị lớn nhất. Phải kiểm tra cả hai chiều vì chỉ một chiều bằng 1 mới cho quan hệ nhiều-một, chưa đủ để kết luận hai cột tương đương. Khi cả hai bằng 1, hai cột chứa cùng thông tin nên giữ cả hai chỉ gây đa cộng tuyến. Nhóm giữ education_num vì nó đã là biến có thứ tự (số cao hơn là học vấn cao hơn) và dùng ngay được cho mô hình, trong khi giữ cột chữ sẽ phải one-hot tạo thêm 15 cột và mất thông tin thứ tự. File được lưu với index=False để chỉ số dòng không bị ghi thành một cột thừa, và dòng in kích thước giúp xác nhận bản sạch có đủ dòng và cột.

2.7. Mã hóa biến phân loại:

- Ô 28: Mã hóa biến phân loại

```
df_enc = df.copy()
df_enc["income"] = (df_enc["income"] == ">50K").astype(int)          # 1 = trên 50K
df_enc["sex"] = (df_enc["sex"] == "Male").astype(int)                # 1 = Male
df_enc["is_us"] = (df_enc["native_country"] == "United-States").astype(int)

nominal = ["workclass", "marital_status", "occupation", "relationship", "race"]
df_enc = pd.get_dummies(df_enc, columns=nominal, drop_first=True, dtype=int)

df_enc = df_enc.drop(columns=["native_country", "fnlwgt", "capital_gain", "capital_loss"])
print("Kích thước sau mã hóa:", df_enc.shape)
print("Còn cột chữ nào không? ->", df_enc.select_dtypes(exclude="number").columns.tolist())   # kỳ vọng []
```

Ô này chuyển các cột chữ về dạng số để mô hình sử dụng được, cho ra bảng 32.537 dòng × 49 cột (48 đặc trưng và 1 nhãn) không còn cột chữ nào. Income và sex chỉ có hai giá trị nên đổi thẳng sang 0/1. Native_country có 41 nhóm nhưng khoảng 91% là United-States, nên one-hot sẽ tạo khoảng 40 cột rất thưa (có nước chỉ 1 dòng); nhóm rút gọn thành is_us.

Năm biến danh nghĩa được mã hóa one-hot thay vì label encoding. Label encoding gán số theo thứ tự chữ cái (Sales là 11, Tech-support là 12) khiến mô hình hiểu các nhóm có thứ tự và khoảng cách thật, trong khi mã số không liên quan đến thu nhập: Exec-managerial (mã 3) có 48,4% trên 50K nhưng Farming-fishing (mã 4) liền kề chỉ có 11,6%. Điều này gây hại cho mô hình tuyến tính và mô hình dựa trên khoảng cách; với mô hình dạng cây, label encoding vẫn chấp nhận được, nhưng one-hot an toàn và dễ giải thích hơn.

Drop_first=True bỏ một nhóm của mỗi biến vì tổng các cột one-hot luôn bằng 1, trùng với hệ số chặn (dummy variable trap). Trên workclass, 9 cột one-hot cộng hệ số chặn có 10 cột nhưng ma trận chỉ có hạng 9, nên hồi quy không chính quy hóa không xác định được hệ số duy nhất. Nhóm bị bỏ là nhóm tham chiếu (workclass là Federal-gov), và hệ số các nhóm còn lại đọc là chênh lệch so với nó. Cuối cùng, nhóm bỏ các cột gốc đã có bản thay thế (native_country, fnlwgt, capital_gain, capital_loss)

2.8. Chia tập dữ liệu và chuẩn hóa:

- Ô 29: Chia tập và chuẩn hóa

```
X = df_enc.drop(columns="income")                    # đặc trưng
y = df_enc["income"]                                 # nhãn

# stratify=y giữ tỷ lệ >50K ở cả hai tập; random_state để kết quả lặp lại được
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, stratify=y, random_state=42)

cols_scale = ["age", "education_num", "hours_per_week", "fnlwgt_log", "capital_gain_log", "capital_loss_log"]
scaler = StandardScaler().fit(X_train[cols_scale])     # chỉ học mean/std từ tập train

X_train_s, X_test_s = X_train.copy(), X_test.copy()
X_train_s[cols_scale] = scaler.transform(X_train[cols_scale])
X_test_s[cols_scale] = scaler.transform(X_test[cols_scale])

print("Tỷ lệ >50K: train =", round(y_train.mean(), 4), "| test =", round(y_test.mean(), 4))
display(X_train_s[cols_scale].describe().loc[["mean", "std"]].round(3))   # kỳ vọng mean ~ 0, std ~ 1
```

Ô này chia dữ liệu đã mã hóa thành tập huấn luyện (80%) và tập kiểm tra (20%), rồi chuẩn hóa sáu biến số bằng StandardScaler, để chuẩn bị cho huấn luyện mô hình mà không để thông tin của tập kiểm tra lọt vào bước chuẩn bị. Kết quả: tỷ lệ thu nhập trên 50K ở cả hai tập đều là 0,2409, và trên tập huấn luyện mean xấp xỉ 0, độ lệch chuẩn xấp xỉ 1.

Nhóm dùng stratify=y để hai tập giữ nguyên tỷ lệ lớp mục tiêu (nhãn mất cân bằng, khoảng 76% dưới 50K và 24% trên 50K) và random_state=42 để kết quả lặp lại được. StandardScaler phù hợp vì age, education_num và hours_per_week có phân phối gần đối xứng; ba biến lệch mạnh đã được log1p trước đó, vì StandardScaler chỉ đưa các biến về cùng thang đo chứ không sửa độ lệch. MinMaxScaler không được chọn vì quá nhạy với ngoại lệ (giá trị 99.999 ép phần lớn dữ liệu về sát 0), RobustScaler cũng không vì capital_gain và capital_loss có IQR bằng 0 nên thư viện đặt hệ số chia bằng 1 và giá trị lớn gần như không

đổi. Scaler chỉ fit trên tập huấn luyện rồi dùng chính các tham số đó cho cả hai tập, vì nếu học trên toàn bộ dữ liệu thì tập kiểm tra đã ảnh hưởng đến bước chuẩn bị, làm đánh giá lạc quan hơn thực tế. Các cột nhị phân không cần chuẩn hóa vì đã ở thang 0 đến 1.

2.9. Tổng kết và lưu kết quả:

- Ô 30: Tổng kết và lưu kết quả

```
tong_ket = pd.DataFrame({
    "Trước": [df_before.shape[0], int(df_before.isna().sum().sum()), int(df_before.duplicated().sum()),
              round(df_before["capital.gain"].skew(), 2)],
    "Sau": [df.shape[0], int(df.isna().sum().sum()), int(df.duplicated().sum()),
            round(df["capital_gain_log"].skew(), 2)],
}, index=["Số dòng", "Số ô thiếu", "Số dòng trùng", "Skew của capital_gain (Sau = bản log1p)"])
display(tong_ket)

df_enc.to_csv("adult_encoded.csv", index=False)
print("Đã lưu adult_clean.csv và adult_encoded.csv")
```

Ô này lập một bảng so sánh bốn chỉ số của dữ liệu trước và sau khi làm sạch, gồm số dòng, số ô thiếu, số dòng trùng và độ lệch của capital_gain. Sau đó ô này lưu dữ liệu đã mã hóa thành file adult_encoded.csv.

Bảng này là minh chứng tổng hợp về hiệu quả của toàn bộ quá trình tiền xử lý, và file đầu ra là đầu vào cho giai đoạn tiếp theo. Kết quả: số dòng giảm từ 32.561 xuống 32.537, số ô thiếu từ 4.262 xuống 0, số dòng trùng từ 24 xuống 0, và skewness của capital_gain từ 11,95 xuống 3,09. Như vậy dữ liệu chỉ mất 24 dòng (khoảng 0,07%) trong khi hai vấn đề chất lượng chính là ô thiếu và dòng trùng đã được xử lý triệt để.

Bảng chỉ chọn bốn chỉ số đại diện cho bốn nhóm vấn đề đã xử lý (quy mô dữ liệu, giá trị thiếu, dữ liệu trùng, phân phối lệch). Cột "Sau" của dòng skewness dùng capital_gain_log (bản đã qua log1p) chứ không dùng cột gốc, vì phép biến đổi được áp dụng lên cột mới và cột gốc vẫn giữ nguyên; nhãn của dòng ghi rõ "Sau = bản log1p" để người đọc không hiểu nhầm là hai cột gốc được so sánh với nhau. Cuối cùng, nhóm lưu df_enc với index=False để chỉ số dòng không bị ghi thành một cột thừa, và lưu cả bản sạch (ở ô trước) lẫn bản đã mã hóa để các bước sau có thể chọn bản phù hợp: bản sạch dễ đọc, dùng cho khám phá dữ liệu, còn bản mã hóa dùng trực tiếp cho mô hình.

C. Giai đoạn 3: Phân tích và trực quan hóa

1. Bức tranh tổng thể

Giai đoạn 3 gồm 10 ô code chạy theo thứ tự. Mỗi ô phụ thuộc vào ô trước nên phải chạy từ trên xuống.

Ô	Nội dung	Giả thuyết
15	Thiết lập, làm sạch lại dữ liệu, viết hàm dùng chung	không
16	Hình 1: phân bố thu nhập	làm mốc

17	Hình 2: tuổi	H1
18	Hình 3: học vấn	H2
19	Hình 4: giới tính	H3
20	Hình 5: giờ làm	H4
21	Hình 6: hôn nhân và nghề nghiệp	H5, H6
22	Hình 7: heatmap tuổi và học vấn	tác động kết hợp
23	Hình 8: ma trận tương quan	xếp hạng yếu tố
24	Bảng tổng kết kiểm định	tổng hợp

Sáu giả thuyết được đặt ra **trước khi vẽ**:
H1: tỷ lệ >50K tăng theo tuổi, đạt đỉnh ở tuổi trung niên rồi giảm (hình chữ U ngược).
H2: học vấn càng cao thì tỷ lệ >50K càng cao.
H3: nam có tỷ lệ >50K cao hơn nữ.
H4: làm nhiều giờ mỗi tuần hơn thì tỷ lệ >50K cao hơn.
H5: người đang kết hôn (civ-spouse) có tỷ lệ >50K cao hơn hẳn nhóm còn lại.
H6: nghề quản lý và chuyên môn có tỷ lệ >50K cao nhất.

Thước đo xuyên suốt: tỷ lệ người có thu nhập >50K trong từng nhóm, không dùng số đếm thô. Lý do: dữ liệu mất cân bằng (khoảng 76% là ≤50K và 24% là >50K). Nếu chỉ đếm số người, nhóm đông luôn trông "cao" dù tỷ lệ thấp. Tỷ lệ nền 24,09% được vẽ thành đường nét đứt trên các biểu đồ để người đọc thấy ngay nhóm nào cao hơn hay thấp hơn mức trung bình.

2. Giai đoạn 1: tự tải dữ liệu

Đây là cell có dòng FILE = “adult.csv”. Bản cũ chỉ kiểm tra xem Colab đã có file adult.csv hay chưa, nếu chưa thì mở hộp thoại upload. Cách này phải sửa vì ổ đĩa Colab trống mỗi khi mở phiên mới, nên lần nào cũng phải upload lại. Bản mới tự đọc bộ dữ liệu từ kho UCI bằng pd.read_csv(url, header=None, names=cols, ...) rồi lưu thành adult.csv. Việc đọc trực tiếp được là nhờ nhóm đưa tên 15 cột vào qua names=cols, vì file gốc của UCI không có dòng tiêu đề. Tên cột được đặt giống bản Kaggle (có dấu chấm, ví dụ hours.per.week) để các cell sau của nhóm chạy nguyên như cũ, còn skipinitialspace=True giúp bỏ khoảng trắng thừa sau dấu phẩy. Ngoài ra còn có phương án dự phòng: nếu tải thất bại do lỗi mạng, khối except sẽ mở hộp thoại upload như cũ, nhờ vậy cell không bao giờ bị kẹt.

3. Giải thích từng ô

Ô 31: Thiết lập, làm sạch lại và hàm hỗ trợ

Đây là ô quan trọng nhất vì mọi ô sau đều dùng biến và hàm do nó tạo ra. Ô này gồm nhiều phần nhỏ.

31a. Import thư viện

Phần này nạp các công cụ cần dùng gồm pandas (bảng dữ liệu), numpy (tính toán), matplotlib và seaborn (vẽ), scipy.stats (kiểm định thống kê), cùng os và math (làm việc với thư mục và phép tính). Lý do cần scipy là vì nó cho phép chạy các kiểm định Chi-square, Mann-Whitney và Spearman. Có kiểm định thì mới nói được "mối liên hệ này có thật" thay vì chỉ "nhìn hình thấy vậy".

31b. Nạp dữ liệu khi chưa có df

Đoạn if "df" not in globals() chỉ chạy khi trong bộ nhớ chưa có biến df, tức là chưa chạy Giai đoạn 1 và 2 hoặc Colab vừa bị reset. Lúc đó nó tự tải dữ liệu từ kho UCI mà không hỏi upload. Mục đích là để Giai đoạn 3 chạy được cả khi chạy riêng lẻ. Nếu df đã có thì đoạn này bỏ qua, không tải lại.

31c. Làm sạch lại theo quy trình Giai đoạn 2

Lệnh	**Tác dụng**	**Vì sao**
dfa = df.copy()	Tạo bản sao tên dfa	Không làm thay đổi df của Giai đoạn 2, tránh phá kết quả đã làm
columns.str.replace(".", "_")	Đổi hours.per.week thành hours_per_week	Tên có dấu chấm dễ gây lỗi khi viết code
replace("?", np.nan)	Đổi ký tự ? thành ô khuyết thật	Trong dữ liệu gốc, ? chỉ là một chuỗi bình thường nên pandas không tính là thiếu
fillna("Unknown") cho workclass, occupation	Gán nhãn "Unknown"	Hai cột này thiếu gần như cùng lúc (người không khai báo). Giữ lại như một nhóm riêng thay vì xóa dòng, vì nhóm có ô thiếu có tỷ lệ >50K khác biệt (13,9% so với 24,9% ở nhóm đủ thông tin)
fillna(mode) cho native_country	Điền giá trị phổ biến nhất (United-States)	Cột này thiếu rất ít (1,79%) và United-States chiếm đa số, nên điền mode gần như không làm lệch dữ liệu
drop_duplicates()	Xóa 24 dòng trùng	Dòng trùng hoàn toàn, kể cả cột fnlwgt, là bản sao ghi nhầm. Nếu bỏ fnlwgt thì có tới 3.533 dòng "trùng", nhưng đó là những người khác nhau tình cờ giống nhau, nên phải giữ fnlwgt khi xét trùng
np.log1p cho capital_gain, capital_loss	Tạo cột _log	Hai cột này lệch phải cực mạnh (độ lệch 11,95), log1p kéo xuống còn 3,09. Dùng

		log1p (log của 1 + x) vì có rất nhiều giá trị 0 mà log(0) không tính được
drop(columns="education")	Xóa cột chữ education	Cột này trùng thông tin với education_num (mỗi bậc học ứng với đúng 1 số)

Vì sao làm lại mà không dùng thẳng df: các bước này chạy nhiều lần vẫn cho cùng kết quả. Nhờ vậy dù df đang là file gốc hay đã làm sạch một phần, dfa cuối cùng luôn đủ cột. Đây cũng là cách khắc phục lỗi KeyError: 'capital_gain_log'.

31d. Tạo biến thu nhập nhị phân và tỷ lệ nền

Biến income_bin nhận giá trị 1 nếu thu nhập >50K và 0 nếu ngược lại. BASE là trung bình của cột này, chính là tỷ lệ nền (24,09%). Lý do làm vậy là khi cột đã ở dạng 0/1 thì trung bình của một nhóm chính là tỷ lệ >50K của nhóm đó, nên groupby(...).mean() tính tỷ lệ rất gọn, và đây cũng là điều kiện để tính tương quan ở Hình 8. Dòng in kiểm tra phải ra 32,537 dòng, con số này khớp với số dòng sau khi nhóm xóa trùng ở Giai đoạn 2.

31e. Màu, thư mục, hàm lưu hình

PALETTE, C_LOW và C_HIGH quy ước xanh luôn là ≤50K, đỏ luôn là >50K. Màu nhất quán giúp người đọc không phải đọc lại chú giải ở mỗi hình. Hàm save_fig lưu hình ra file PNG 150 dpi vào thư mục tạm của Colab, dùng để chèn vào báo cáo PDF.

31f. Bảng EDU_NAMES

Bảng này đổi số education_num (1 đến 16) thành tên bậc học như Preschool, HS-grad, Bachelors, Doctorate... Cột education đã bị xóa ở Giai đoạn 2 nên cần bảng này để trục biểu đồ có tên dễ đọc thay vì con số.

31g. Chia nhóm (binning) bằng pd.cut

Biến mới	**Cách chia**	**Lý do**
age_group	17-24, 25-34, 35-44, 45-54, 55-64, 65+	Tuổi có 73 giá trị, vẽ từng tuổi sẽ rối. Chia theo thập niên tuổi cho thấy xu hướng rõ. right=False nghĩa là khoảng đóng bên trái, nên 25 thuộc nhóm 25-34
hours_grp	≤20, 21-39, 40, 41-50, 51-60, >60	Tách riêng mốc đúng 40 giờ vì 46,7% người làm đúng 40 giờ (toàn thời gian tiêu chuẩn). Nếu gộp, mốc này che mất sự khác biệt
edu_grp	Dưới THPT, HS-grad, Some-college/Assoc, Bachelors, Sau đại học	Giảm 16 bậc xuống 5 nhóm để heatmap ở Hình 7 đủ mẫu mỗi ô
is_married	1 nếu Married-civ-spouse	Nhóm kết hôn thực sự (đang sống cùng vợ/chồng)

is_male	1 nếu Male	Cần dạng số để tính tương quan ở Hình 8

31h. Các hàm hỗ trợ (dùng lại ở nhiều ô)

- rate_table(col): với mỗi nhóm của một cột, trả về n (số người), rate (tỷ lệ >50K) và rate_%. Dùng observed=True để pandas không báo cảnh báo với biến chia nhóm.
- cramers_v(ct): đo độ mạnh của liên hệ giữa hai biến phân loại, từ 0 (không liên hệ) đến 1 (liên hệ hoàn toàn).
- chi2_test(series): chạy kiểm định Chi-square giữa một biến phân loại và income, trả về chi2, p-value, bậc tự do và Cramér's V.
- mw_test(col): chạy Mann-Whitney U để so sánh một biến số giữa nhóm >50K và ≤50K, trả về p-value và AUC.
- fmt_p(p): in p-value dạng khoa học cho gọn; p nhỏ hơn 1e-300 thì in "<1e-300" vì máy tính không biểu diễn được.
- bar_text(...): ghi nhãn số lên đầu mỗi cột biểu đồ.
- ket_qua = []: danh sách rỗng, mỗi ô sau sẽ thêm kết quả kiểm định của mình vào, đến Ô 10 gom thành bảng tổng kết.

Vì sao viết hàm: mỗi phép tính được dùng 3 đến 6 lần. Viết một lần thì code ngắn hơn và nếu cần sửa chỉ sửa một chỗ.

Ô 32: Hình 1, phân bố thu nhập

Biểu đồ cột này là hình đơn giản đếm số người thuộc nhóm ≤50K và nhóm >50K. Tác dụng của nó là cho thấy dữ liệu mất cân bằng, cứ khoảng 3 người ≤50K thì có 1 người >50K, và đây là mốc để đọc mọi hình sau. Lý do chọn biểu đồ cột là vì chỉ có 2 nhóm nên cột là cách trực quan nhất, với nhãn trên mỗi cột ghi cả số người lẫn phần trăm. Phần in số liệu đi kèm là một bảng số lượng và tỷ lệ phần trăm của hai nhóm, cộng thêm tỷ lệ giữa hai nhóm, và các con số này được dùng để viết Deep Insight.

Ô 33: Hình 2, tuổi và thu nhập (H1)

Hình có 2 biểu đồ cạnh nhau:

(a) Biểu đồ phân phối (histogram): hai nhóm thu nhập chồng lên nhau, kèm đường chấm là tuổi trung vị mỗi nhóm. Vì sao: cho thấy "ai ở đâu" về mặt tuổi. Dùng stat="density" và common_norm=False để chuẩn hóa mỗi nhóm về cùng diện tích, nhờ đó so sánh công bằng dù nhóm ≤50K đông gấp 3 lần.

(b) Biểu đồ đường: tỷ lệ >50K theo nhóm tuổi. Vì sao dùng đường: tuổi là biến có thứ tự, đường nối các điểm thể hiện được **xu hướng** (tăng rồi giảm). Mỗi điểm ghi kèm n để biết nhóm đó đông hay thưa.

Kiểm định: Mann-Whitney U so sánh tuổi giữa hai nhóm thu nhập. Vì sao không dùng t-test: phân phối tuổi không chuẩn, Mann-Whitney không đòi hỏi phân phối chuẩn.

Quy tắc kết luận H1: giả thuyết được ủng hộ khi nhóm tuổi có tỷ lệ cao nhất **không nằm ở hai đầu** (không phải nhóm trẻ nhất hay già nhất) và $p < 0,05$. Nghĩa là có hình chữ U ngược thật sự.

Ô 34: Hình 3, học vấn và thu nhập (H2)

Đây là biểu đồ cột ngang, mỗi cột ứng với một bậc học và được xếp từ thấp lên cao. Lý do chọn cột ngang là vì tên bậc học khá dài (Some-college, Prof-school), nên cột ngang giúp đọc dễ hơn. Cột đỏ là nhóm có tỷ lệ >50K cao hơn mức nền, còn cột xanh là nhóm thấp hơn mức nền, nhờ vậy người đọc thấy ngay từ bậc học nào trở đi thì tỷ lệ vượt mức trung bình.

- Kiểm định: ba phép đo bổ sung nhau.
  - **Spearman ở mức cá nhân:** tương quan hạng giữa số năm học và income.
  - **Spearman ở mức nhóm:** đo xem tỷ lệ >50K có tăng đều theo bậc học không (đơn điệu). Giá trị gần 1 nghĩa là bậc học càng cao thì tỷ lệ càng cao, gần như không có ngoại lệ.
  - **Chi-square và Cramér's V:** cho biết mối liên hệ có thật không và mạnh cỡ nào.

Spearman được dùng thay cho Pearson vì học vấn là biến có thứ tự chứ không phải biến có khoảng cách đều giữa các bậc, mà Spearman chỉ quan tâm đến thứ hạng nên phù hợp hơn. Ngoài ra, ô này còn tìm "bậc học đầu tiên vượt tỷ lệ nền" và tính các tỷ số, chẳng hạn Bachelors gấp bao nhiêu lần HS-grad, để có số liệu cụ thể phục vụ phần nhận xét.

Ô 35: Hình 4, giới tính và thu nhập (H3)

Hình có 2 biểu đồ:

(a) tỷ lệ >50K của nam và nữ (chênh lệch thô).

(b) cùng so sánh nam và nữ nhưng **tách riêng theo tình trạng hôn nhân** (đang kết hôn và nhóm còn lại).

Vì sao làm biểu đồ (b): chênh lệch nam và nữ ở (a) có thể không hoàn toàn do giới tính. Nếu nam kết hôn nhiều hơn nữ, và kết hôn làm tăng tỷ lệ >50K, thì một phần chênh lệch đến từ hôn nhân. Tách theo hôn nhân là cách kiểm tra **yếu tố gây nhiễu (confounder)**. Nếu trong cùng nhóm hôn nhân khoảng cách vẫn còn, thì giới tính có tác động riêng.

Phần in số liệu còn có hai bảng kiểm tra thêm: tỷ lệ kết hôn theo giới và tỷ lệ >50K theo giới **tách theo nhóm giờ làm**. Mục đích như trên: kiểm tra xem khoảng cách có biến mất khi so sánh cùng điều kiện giờ làm không.

Ô 36: Hình 5, giờ làm việc và thu nhập (H4)

(a) biểu đồ cột tỷ lệ >50K theo nhóm giờ làm.

(b) biểu đồ hộp (boxplot) phân phối giờ làm của hai nhóm thu nhập.

Vì sao hai biểu đồ: (a) trả lời "giờ làm nào thì tỷ lệ cao?", (b) cho thấy phân phối thật (trung vị, độ rộng, ngoại lệ) của hai nhóm. Boxplot cũng cho thấy phần lớn người làm đúng 40 giờ nên hộp rất hẹp.

Kiểm định: Mann-Whitney U. Dùng thay cho t-test vì giờ làm không có phân phối chuẩn (46,7% dồn vào đúng 40 giờ).

Quy tắc kết luận H4: tỷ lệ của nhóm làm hơn 40 giờ phải cao hơn nhóm đúng 40 giờ, và nhóm đúng 40 giờ phải cao hơn nhóm dưới 40 giờ (xu hướng tăng liên tục), và $p < 0,05$.

Ô 37: Hình 6, hôn nhân và nghề nghiệp (H5, H6)

Hai biểu đồ cột ngang cạnh nhau, **xếp theo tỷ lệ tăng dần** (nhóm cao nhất nằm trên cùng).

Biểu đồ dùng cột ngang và xếp theo thứ tự tỷ lệ vì đây là hai biến phân loại có nhiều nhóm, không có thứ tự tự nhiên. Xếp theo tỷ lệ giúp thấy ngay nhóm cao nhất và thấp nhất. Về kiểm định, ô này chạy Chi-square và Cramér's V cho từng biến. Cramér's V cho biết biến nào có liên hệ mạnh hơn với income, nên đây là cách so sánh công bằng giữa hôn nhân và nghề nghiệp.

Quy tắc kết luận được đặt như sau: H5 đúng khi tỷ lệ của nhóm civ-spouse cao hơn các nhóm còn lại gộp lại và $p < 0,05$, còn H6 đúng khi hai nghề có tỷ lệ cao nhất đúng là Exec-managerial và Prof-specialty. Mỗi cột đều ghi kèm n. Cần chú ý các nhóm có n rất nhỏ (ví dụ Married-AF-spouse, Armed-Forces) vì tỷ lệ của chúng không đáng tin.

Ô 38: Hình 7, heatmap tuổi và học vấn

Đây là biểu đồ bảng màu (heatmap), mỗi ô là tỷ lệ >50K của một tổ hợp nhóm tuổi × nhóm học vấn, màu càng đậm thì tỷ lệ càng cao. Các hình trước chỉ xét từng yếu tố riêng lẻ, còn heatmap cho thấy hai yếu tố cùng lúc, chẳng hạn học vấn cao có phải chỉ có lợi khi đã đủ tuổi không, hay người trẻ học cao có vẫn chưa đạt thu nhập cao không. Heatmap được chọn vì đây là loại biểu đồ chuẩn cho dữ liệu hai chiều dạng lưới.

Những ô có $n < 30$ được che đi, để trống, vì tỷ lệ tính trên dưới 30 người rất dao động và dễ gây hiểu lầm. Phần in số liệu đi kèm tìm ô cao nhất, ô thấp nhất, rồi so sánh trong cùng nhóm tuổi hoặc cùng nhóm học vấn.

Ô 39: Hình 8, ma trận tương quan

- Hai biểu đồ.

  (a) ma trận tương quan giữa income và 7 biến (tuổi, học vấn, giờ làm, capital_gain_log, capital_loss_log, giới tính, kết hôn). Chỉ hiện nửa dưới ma trận vì nửa trên lặp lại.

  (b) cột ngang xếp hạng các biến theo độ mạnh tương quan với income.

Biểu đồ này trả lời câu hỏi "yếu tố nào liên quan mạnh nhất đến thu nhập" bằng một con số duy nhất cho mỗi yếu tố, và là cầu nối sang Giai đoạn 4 (yếu tố cốt lõi). Các biến được dùng là income_bin, is_male và is_married vì tương quan chỉ tính được trên dữ liệu số. Khi một biến ở dạng 0/1 thì hệ số tương quan Pearson được gọi là point-biserial và vẫn diễn giải được bình thường. Nhóm dùng capital_gain_log thay vì capital_gain vì giá trị gốc lệch cực mạnh, 91,7% bằng 0, và một vài giá trị rất lớn (như 99999) làm hệ số tương quan thiếu ổn định. Phép log giúp dữ liệu cân đối hơn.

Ô này tự tạo hai cột log nếu thiếu: ba dòng đầu của ô kiểm tra và tạo hai cột đó, nên chạy riêng ô này cũng không bị lỗi.

Ô 40: Bảng tổng kết

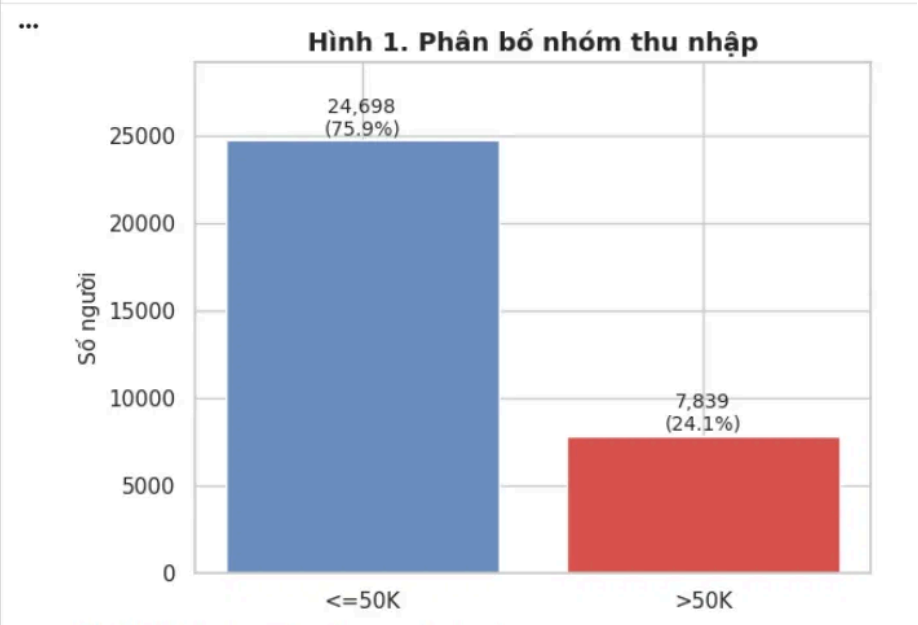
Ô này gom danh sách ket_qua (từ các ô 3 đến 7) thành một bảng duy nhất. Tác dụng là cho một cái nhìn tổng hợp: giả thuyết nào được ủng hộ hay bác bỏ, bằng kiểm định nào, p-value bao nhiêu, độ lớn hiệu ứng ra sao. Đây chính là phần "kiểm định giả thuyết" mà đề

bài yêu cầu. Kèm theo là một ghi chú đọc kết quả, nhắc rằng với hơn 32.000 dòng thì p-value gần như luôn rất nhỏ, nên phải xem thêm độ lớn hiệu ứng. Ô này không lưu hay tải file nào về máy. Hình được lưu ở thư mục tạm của Colab, muốn lấy thì bấm chuột phải vào hình và chọn Save image as.

4. Phân tích chi tiết kết quả và kiểm định các giả thuyết

4.1. Nhận xét Hình 1: Phân bố nhóm thu nhập

Trước khi tìm hiểu yếu tố nào ảnh hưởng đến thu nhập, nhóm xem xét bức tranh chung của tập dữ liệu. Hình 1 thể hiện số lượng và tỷ lệ của hai nhóm thu nhập trong 32.537 quan sát.



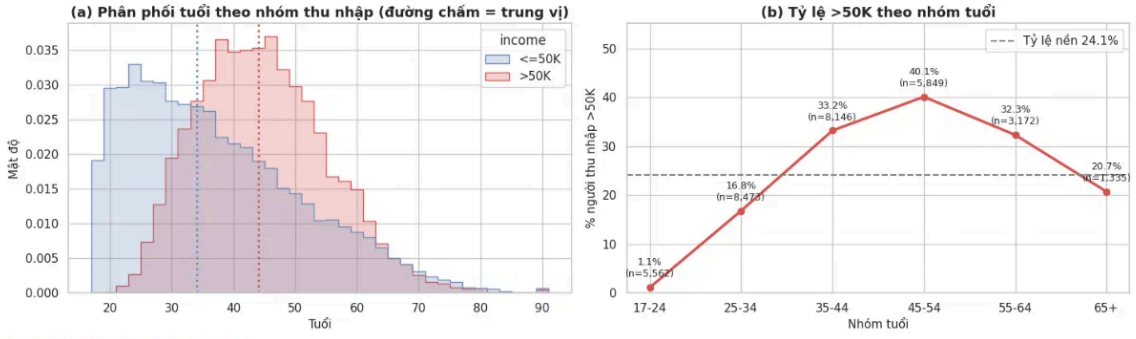
Kết quả cho thấy sự chênh lệch rõ rệt: nhóm ≤50K có 24.698 người (75,9%), trong khi nhóm >50K chỉ có 7.839 người (24,1%). Tỷ lệ giữa hai nhóm là khoảng 3,15 : 1, nghĩa là cứ 3 người có thu nhập từ 50K trở xuống thì mới có 1 người vượt ngưỡng này.

Điều này cho thấy thu nhập >50K là đặc điểm tương đối hiếm và dữ liệu bị mất cân bằng giữa hai nhóm. Vì vậy, ở các hình tiếp theo, nhóm so sánh tỷ lệ % người >50K trong từng nhóm với mức nền 24,1% thay vì so sánh số lượng tuyệt đối, vì số lượng tuyệt đối luôn nghiêng về nhóm ≤50K.

4.2. Nhận xét Hình 2: Tuổi tác và thu nhập

Câu hỏi đặt ra là người có thu nhập cao có thực sự lớn tuổi hơn không, và thu nhập có tăng mãi theo tuổi hay không. Hình 2 trả lời bằng hai góc nhìn: phân phối tuổi của hai nhóm (a) và tỷ lệ >50K theo từng nhóm tuổi (b).

Hình 2. Tuổi tác và thu nhập



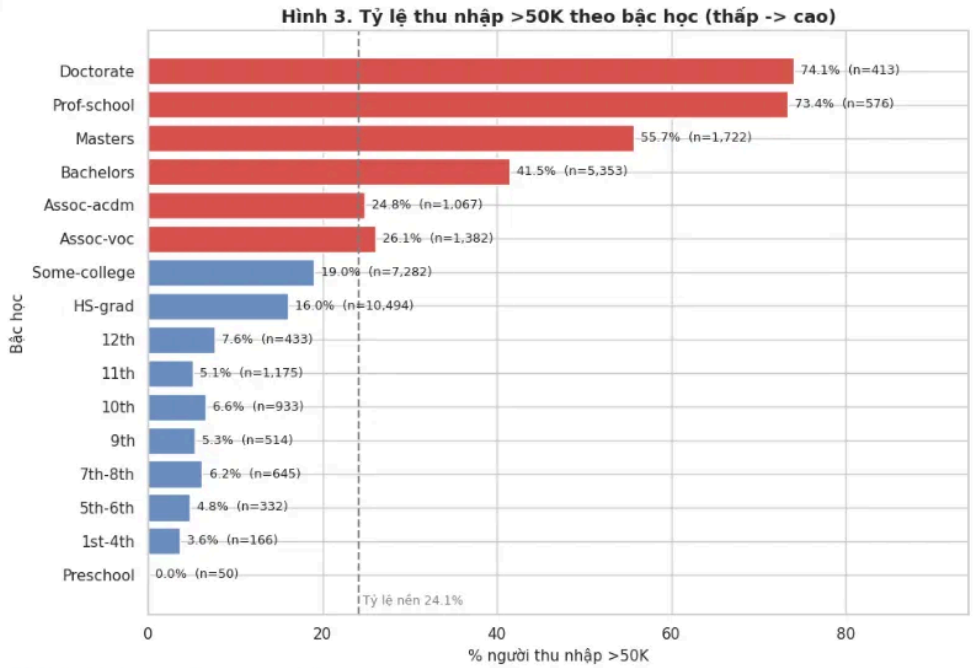
Ở hình (a), hai phân phối tách biệt khá rõ. Nhóm ≤50K tập trung dày ở độ tuổi 20-30 rồi giảm dần, còn nhóm >50K có đỉnh ở khoảng 40-50 tuổi và rất ít người dưới 25. Tuổi trung vị của nhóm >50K là 44, cao hơn nhóm ≤50K (34) đúng 10 tuổi. Kiểm định Mann-Whitney U cho $p < 0,001$ với AUC = 0,684: nếu chọn ngẫu nhiên một người từ mỗi nhóm, có khoảng 68,4% khả năng người thuộc nhóm >50K lớn tuổi hơn. Như vậy sự khác biệt có ý nghĩa thống kê, nhưng mức tách biệt chỉ ở mức trung bình.

Hình (b) cho thấy rõ hơn hình dạng của mối quan hệ. Tỷ lệ >50K tăng nhanh từ 1,1% (17-24 tuổi) lên 16,8% (25-34), 33,2% (35-44) và đạt đỉnh 40,1% ở nhóm 45-54, gấp khoảng 1,67 lần mức nền. Sau đó tỷ lệ giảm xuống 32,3% (55-64) và còn 20,7% ở nhóm 65+, thấp hơn cả mức nền 24,1%.

Đường biểu diễn có dạng chữ U ngược, do đó giả thuyết H1 được ủng hộ. Có thể giải thích rằng người trẻ mới vào thị trường lao động nên lương khởi điểm thấp, thu nhập tích lũy theo kinh nghiệm và vị trí công việc, đạt đỉnh ở tuổi trung niên, rồi giảm khi chuyển sang làm bán thời gian hoặc nghỉ hưu. Tuy nhiên, đây là dữ liệu cắt ngang nên chỉ phản ánh mối liên hệ giữa các nhóm tuổi tại một thời điểm, không chứng minh quan hệ nhân quả.

4.3. Nhận xét Hình 3: Tỷ lệ thu nhập >50K theo bậc học

Sau khi xem xét tuổi tác, câu hỏi tiếp theo là học vấn càng cao thì khả năng đạt thu nhập cao có càng lớn không. Hình 3 xếp các bậc học từ thấp đến cao và so sánh tỷ lệ >50K của từng bậc với mức nền 24,1% (đường nét đứt).



Biểu đồ cho thấy tỷ lệ tăng gần như đơn điệu theo bậc học. Ở nhóm học vấn thấp, tỷ lệ chỉ vài phần trăm: 0,0% (Preschool), 3,6% (1st-4th), 4,8% (5th-6th) và từ 5,1% đến 7,6% ở các bậc 9th-12th. Nhóm tốt nghiệp phổ thông (HS-grad, n=10.494, đông nhất) đạt 16,0%, và nhóm Some-college đạt 19,0%, vẫn thấp hơn mức nền. Bước chuyển nằm ở bậc Associate: Assoc-acdm (24,8%) và Assoc-voc (26,1%) là hai bậc đầu tiên vượt mức nền. Từ đó tỷ lệ tăng mạnh: Bachelors 41,5%, Masters 55,7%, Prof-school 73,4% và Doctorate 74,1%. So với nhóm HS-grad, người có bằng Bachelors có tỷ lệ >50K gấp 2,60 lần, còn Doctorate gấp 4,64 lần. Ở hai bậc cao nhất, khoảng ba phần tư số người đã vượt ngưỡng 50K.

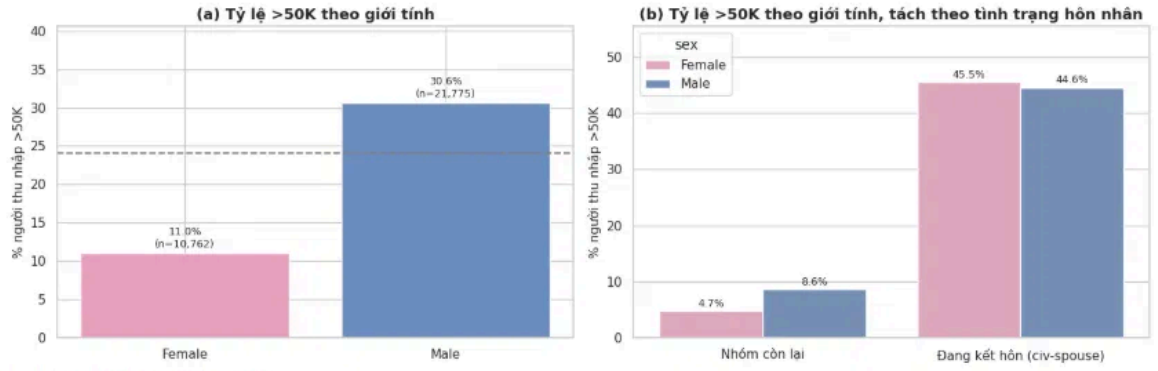
Các kiểm định xác nhận nhận định này. Chi-square cho $chi^2 = 4.428$, dof = 15, $p < 0,001$ và Cramér's V = 0,369, cho thấy mối liên hệ có ý nghĩa thống kê với cường độ trung bình đến khá. Hệ số Spearman ở cấp cá nhân là rho = 0,330, trong khi theo nhóm bậc học là 0,976. Chênh lệch này cho thấy xu hướng chung rất rõ, nhưng giữa các cá nhân vẫn còn nhiều dao động, tức là học vấn cao không đảm bảo thu nhập cao.

Vì vậy giả thuyết H2 được ủng hộ: bậc học càng cao thì tỷ lệ thu nhập >50K càng lớn, trong đó bằng đại học là mốc quan trọng để vượt mức nền và bậc sau đại học mang lại lợi thế rõ hơn nữa. Cần lưu ý hai điểm: các bậc rất thấp như Preschool (n=50) và 1st-4th (n=166) có cỡ mẫu nhỏ nên tỷ lệ kém ổn định; và học vấn còn đan xen với nghề nghiệp, tuổi, số giờ làm nên chưa thể kết luận đây là nguyên nhân trực tiếp.

4.4. Nhận xét Hình 4: Giới tính và thu nhập

Sau tuổi và học vấn, câu hỏi tiếp theo là giới tính có liên hệ với khả năng đạt thu nhập cao hay không, và chênh lệch này có phải do yếu tố khác (như hôn nhân, giờ làm) hay không. Hình 4 trả lời bằng hai góc nhìn: tỷ lệ >50K theo giới tính (a) và tỷ lệ này khi tách theo tình trạng hôn nhân (b).

Hình 4. Giới tính và thu nhập



Ở hình (a), khoảng cách giữa hai giới rất lớn. Nam có tỷ lệ >50K là 30,6% (n=21.775), vượt mức nền 24,1%, trong khi nữ chỉ đạt 11,0% (n=10.762), thấp hơn mức nền hơn một nửa. Chênh lệch là 19,6 điểm phần trăm, nam gấp khoảng 2,79 lần nữ. Kiểm định Chi-square cho $chi^2 = 1.517$, $p < 0,001$ và Cramér's $V = 0,216$, cho thấy sự khác biệt có ý nghĩa thống kê với cường độ ở mức nhẹ đến trung bình.

Tuy nhiên, chênh lệch thô này chưa chắc hoàn toàn do giới tính. Nhóm kiểm tra yếu tố gây nhiễu là hôn nhân: trong dữ liệu, 61,1% nam đang kết hôn (civ-spouse) so với chỉ 15,4% nữ, và hình (b) cho thấy kết hôn đi kèm tỷ lệ >50K cao hơn hẳn. Khi tách theo hôn nhân:

Nhóm đang kết hôn: nữ 45,5%, nam 44,6%, gần như ngang nhau (nữ thậm chí nhỉnh hơn 0,9 điểm).

Nhóm còn lại: nữ 4,7%, nam 8,6%, nam vẫn cao hơn khoảng 3,9 điểm nhưng cả hai đều rất thấp.

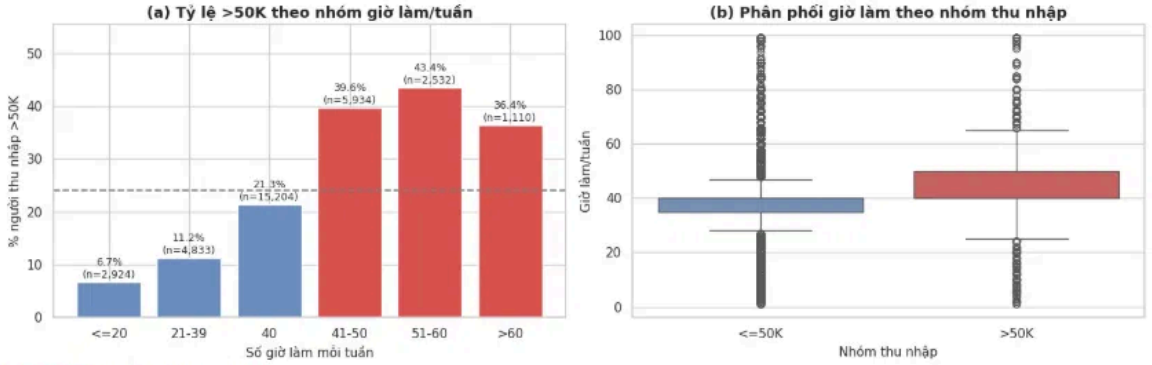
Điều này cho thấy phần lớn khoảng cách 19,6 điểm ở hình (a) đi cùng với sự khác biệt về tình trạng hôn nhân giữa hai giới, chứ không chỉ riêng giới tính. Bảng tách theo giờ làm cho thấy một yếu tố gây nhiễu khác: nam vẫn cao hơn nữ ở mọi nhóm giờ làm (≤20 giờ: 7,6% so với 5,9%; 21-39 giờ: 14,3% so với 8,5%; đúng 40 giờ: 26,7% so với 10,2%), và khoảng cách lớn nhất (16,5 điểm) nằm ở nhóm làm đúng 40 giờ. Như vậy giờ làm không giải thích hết chênh lệch.

Vì vậy giả thuyết H3 được ủng hộ: nam có tỷ lệ >50K cao hơn nữ. Tuy nhiên đây là phân tích mô tả, chỉ cho thấy có chênh lệch chứ không xác định được nguyên nhân (có thể liên quan đến chọn nghề, cấu trúc hộ gia đình, thời gian nghỉ chăm con, hoặc các yếu tố khác). Kết quả ở nhóm kết hôn cũng cần đọc thận trọng: biến hôn nhân trong dữ liệu có thể phản ánh thu nhập hộ gia đình chứ không chỉ thu nhập cá nhân.

4.5. Nhận xét Hình 5: Giờ làm việc và thu nhập

Sau giới tính, câu hỏi tiếp theo là làm nhiều giờ hơn mỗi tuần có đi kèm khả năng thu nhập cao hơn hay không. Hình 5 trả lời bằng hai góc nhìn: tỷ lệ >50K theo nhóm giờ làm (a) và phân phối giờ làm của hai nhóm thu nhập (b).

Hình 5. Giờ làm việc và thu nhập

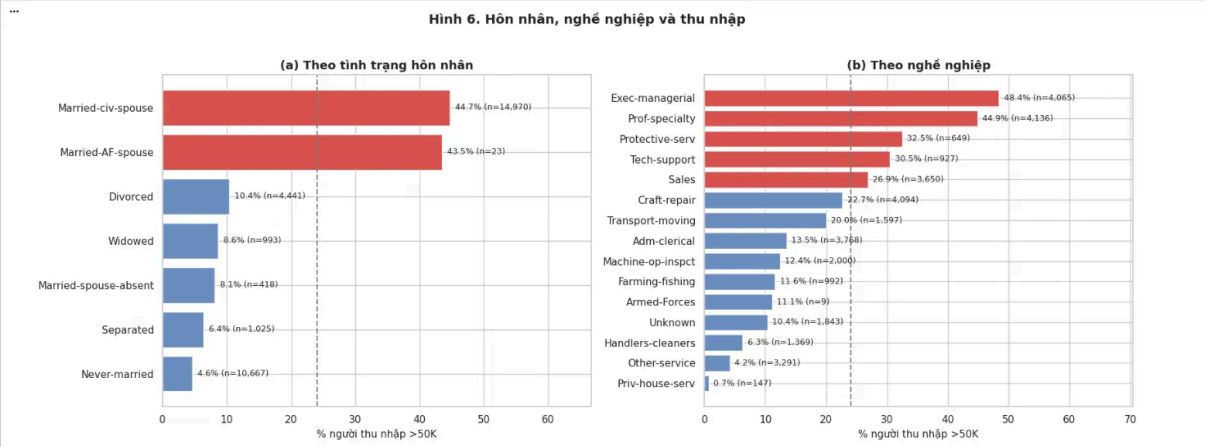


Ở hình (a), tỷ lệ >50K tăng theo số giờ làm. Nhóm làm ≤20 giờ/tuần chỉ đạt 6,7% (n=2.924), nhóm 21-39 giờ đạt 11,2% (n=4.833), và nhóm đúng 40 giờ đạt 21,3% (n=15.204), vẫn thấp hơn mức nền 24,1%. Từ trên 40 giờ trở đi, tỷ lệ vượt mức nền rõ rệt: 39,6% ở nhóm 41-50 giờ (n=5.934), đạt đỉnh 43,4% ở nhóm 51-60 giờ (n=2.532), và 36,4% ở nhóm trên 60 giờ (n=1.110). Gộp lại, nhóm làm dưới 40 giờ có tỷ lệ >50K là 9,5%, nhóm đúng 40 giờ là 21,3%, còn nhóm trên 40 giờ là 40,3%, tức gấp khoảng 1,9 lần nhóm đúng 40 giờ và gấp hơn 4 lần nhóm dưới 40 giờ. Điểm đáng chú ý là nhóm trên 60 giờ (36,4%) thấp hơn nhóm 51-60 giờ (43,4%), nghĩa là tỷ lệ không tăng mãi mà có dấu hiệu chững lại và giảm nhẹ ở mức làm việc rất nhiều giờ.

Hình (b) cho thấy phân phối thực của hai nhóm. Hộp của nhóm ≤50K nằm ở khoảng 35-40 giờ, còn hộp của nhóm >50K nằm ở khoảng 40-50 giờ, với giờ làm trung vị lần lượt là 40 (nhóm >50K) và 40 (nhóm ≤50K). Hai trung vị trùng nhau vì có tới 46,7% tổng số người làm đúng 40 giờ, nên điểm khác biệt nằm ở phần đuôi: nhóm >50K có phần lớn người làm từ 40 giờ trở lên, trong khi nhóm ≤50K có nhiều người làm dưới 40 giờ. Cả hai nhóm đều có nhiều giá trị ngoại lệ ở hai đầu (rất ít giờ hoặc gần 100 giờ/tuần). Kiểm định Mann-Whitney U cho $p < 0,001$ và AUC = 0,672, nghĩa là nếu chọn ngẫu nhiên một người từ mỗi nhóm thì có khoảng 67,2% khả năng người thuộc nhóm >50K làm nhiều giờ hơn. Hệ số Spearman rho = 0,269 cho thấy tương quan thuận ở mức nhẹ đến trung bình.

Vì vậy giả thuyết H4 được ủng hộ: làm nhiều giờ hơn đi cùng tỷ lệ >50K cao hơn. Tuy nhiên cần đọc thận trọng: mối liên hệ này không đồng nghĩa làm thêm giờ sẽ tăng thu nhập, vì người có thu nhập cao thường ở các vị trí quản lý, chuyên môn hoặc tự kinh doanh vốn đã làm nhiều giờ; chiều nhân quả có thể đi theo cả hai hướng. Ngoài ra, người làm đúng 40 giờ chiếm gần một nửa mẫu, nên mức độ tách biệt giữa hai nhóm ở hình (b) chủ yếu đến từ phần đuôi phân phối.

4.6. Nhận xét Hình 6: Hôn nhân, nghề nghiệp và thu nhập



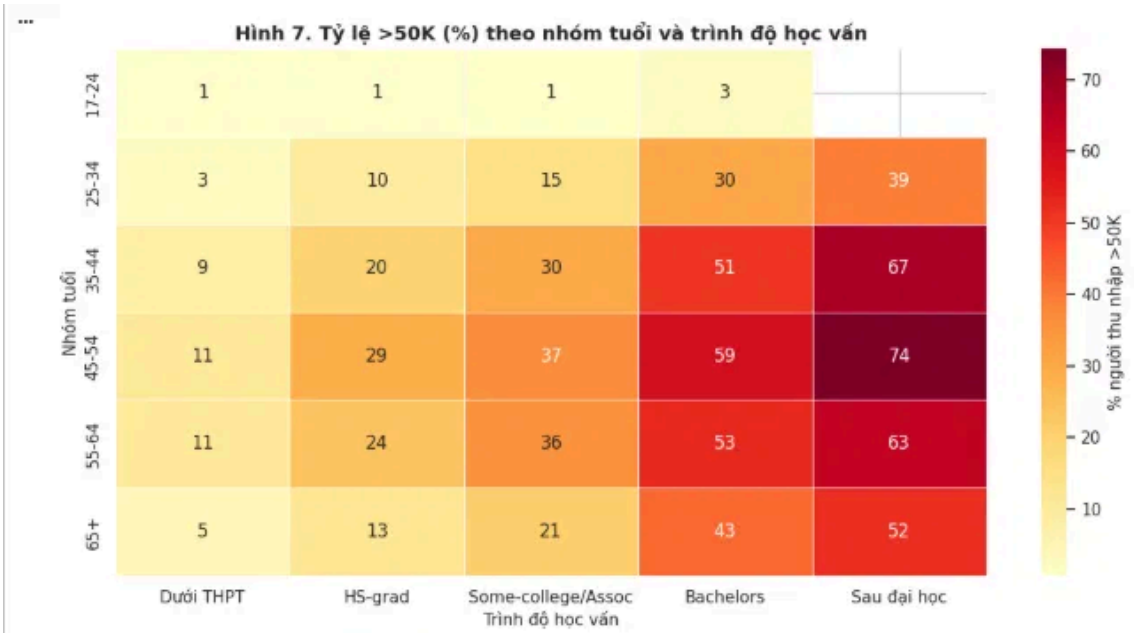
Hình 4 cho thấy tình trạng hôn nhân là một yếu tố đan xen quan trọng với giới tính, nên câu hỏi tiếp theo là tình trạng hôn nhân và nghề nghiệp có liên hệ thế nào với thu nhập cao. Hình 6 trả lời bằng hai biểu đồ cột ngang, xếp theo tỷ lệ >50K giảm dần: theo tình trạng hôn nhân (a) và theo nghề nghiệp (b), kèm đường nét đứt là mức nền 24,1%.

Ở hình (a), khoảng cách giữa các nhóm rất lớn. Nhóm Married-civ-spouse (n=14.970) có tỷ lệ >50K là 44,7%, cao hơn mức nền gần gấp đôi. Các nhóm còn lại đều thấp hơn mức nền: Divorced 10,4% (n=4.441), Widowed 8,6%, Married-spouse-absent 8,1%, Separated 6,4% và thấp nhất là Never-married 4,6% (n=10.667). Gộp các nhóm còn lại, tỷ lệ chỉ là 6,5%, tức nhóm Married-civ-spouse gấp khoảng 6,83 lần. Married-AF-spouse đạt 43,5% nhưng chỉ có n=23, nên con số này kém tin cậy và không nên dùng để kết luận. Kiểm định Chi-square cho $p < 0,001$ và Cramér's $V = 0,447$, cho thấy mối liên hệ có ý nghĩa thống kê và có cường độ khá mạnh.

Ở hình (b), nghề nghiệp cũng phân hóa rõ. Hai nghề cao nhất là Exec-managerial (48,4%, n=4.065) và Prof-specialty (44,9%, n=4.136). Tiếp theo là Protective-serv (32,5%), Tech-support (30,5%) và Sales (26,9%); đây là năm nghề vượt mức nền. Các nghề còn lại đều thấp hơn mức nền, trong đó thấp nhất là Handlers-cleaners (6,3%), Other-service (4,2%, n=3.291) và Priv-house-serv (0,7%, n=147). Nhóm Unknown (người không khai báo nghề) chỉ đạt 10,4%. Chênh lệch giữa nghề cao nhất và thấp nhất là khoảng 47,7 điểm phần trăm. Chi-square cho $p < 0,001$ và Cramér's $V = 0,352$, ở mức trung bình đến khá. Armed-Forces (11,1%) chỉ có n=9 nên không đáng tin.

Vì vậy giả thuyết H5 được ủng hộ (người đang kết hôn civ-spouse có tỷ lệ >50K cao hơn hẳn nhóm còn lại) và giả thuyết H6 được ủng hộ (hai nghề cao nhất đúng là Exec-managerial và Prof-specialty). So sánh theo Cramér's V, hôn nhân (0,447) có liên hệ mạnh hơn nghề nghiệp (0,352) và cả giới tính (0,216) với thu nhập. Tuy nhiên cần đọc thận trọng: dữ liệu điều tra có thể ghi nhận thu nhập ở mức hộ gia đình đối với người đã kết hôn, và nghề nghiệp còn đan xen với học vấn, nên đây chỉ là mối liên hệ thống kê, chưa phải quan hệ nhân quả.

4.7. Nhận xét Hình 7: Tỷ lệ >50K theo nhóm tuổi và trình độ học vấn



Hình 7 đặt tuổi và học vấn cạnh nhau để trả lời hai câu hỏi: học vấn cao có mang lại lợi thế ở mọi độ tuổi không, và người trẻ có bằng cao có đạt thu nhập cao sớm không. Mỗi ô là tỷ lệ >50K (%) của một tổ hợp nhóm tuổi × nhóm học vấn, màu càng đậm thì tỷ lệ càng cao. Ô nào có n < 30 bị để trống (ô nhóm 17-24 × Sau đại học).

Theo chiều học vấn (đọc dọc từng hàng). Ở mọi nhóm tuổi, tỷ lệ >50K tăng theo trình độ học vấn. Trong riêng nhóm 45-54 tuổi, tỷ lệ tăng từ 11% (Dưới THPT) lên 29% (HS-grad), 37% (Some-college/Assoc), 59% (Bachelors) và 74% (Sau đại học). Quy luật này vẫn đúng ở các nhóm tuổi khác, ví dụ nhóm 35-44: 9% → 20% → 30% → 51% → 67%. Như vậy lợi thế của học vấn không chỉ do người học cao tình cờ lớn tuổi hơn, mà vẫn còn khi so sánh trong cùng một độ tuổi.

Theo chiều tuổi (đọc dọc từng cột). Ở mỗi trình độ học vấn, tỷ lệ tăng theo tuổi rồi giảm, đạt đỉnh ở nhóm 45-54, khớp với dạng chữ U ngược ở Hình 2. Với nhóm Bachelors, tỷ lệ là 3% (17-24), 30% (25-34), 51% (35-44), 59% (45-54), 53% (55-64) và 43% (65+). Riêng nhóm Dưới THPT và HS-grad thì đỉnh thấp hơn nhiều (11% và 29%).

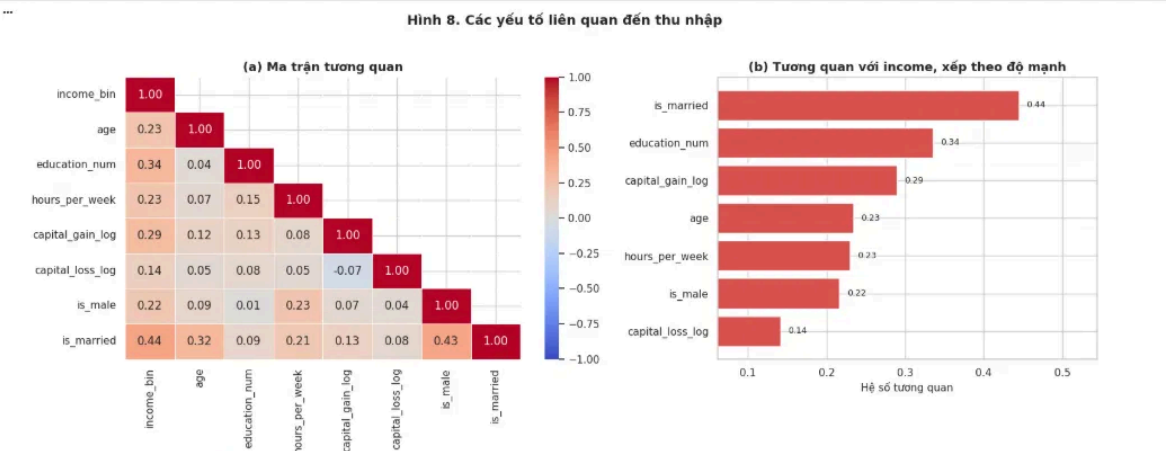
Tác động kết hợp. Ô cao nhất là nhóm 45-54 tuổi có trình độ Sau đại học với 74,2%, gấp khoảng 3 lần mức nền 24,1%. Ô thấp nhất là nhóm 17-24 tuổi trình độ HS-grad với 0,7%. Người trẻ có bằng cao vẫn chưa đạt thu nhập cao sớm: nhóm 17-24 tuổi có Bachelors chỉ đạt 2,7%, trong khi nhóm 25-34 có Bachelors đạt 30,5% và Sau đại học 39,5%. Điều này cho thấy bằng cấp chỉ phát huy tác dụng sau một giai đoạn tích lũy kinh nghiệm. Ngược lại, tuổi cao mà học vấn thấp không bù được: nhóm 45-54 Dưới THPT chỉ đạt 11,2%, thấp hơn nhóm 25-34 có Bachelors (30,5%) rất xa. Đáng chú ý, nhóm 65+ có Sau đại học (52,0%) và Bachelors (42,6%) vẫn cao hơn mức nền, trong khi mọi nhóm 65+ có học vấn từ Some-college/Assoc trở xuống đều thấp hơn mức nền.

Vì vậy, hai yếu tố tác động đồng thời: học vấn quyết định mức trần, còn tuổi quyết định khi nào đạt đến mức trần đó. Đây là mối liên hệ thống kê trên dữ liệu cắt ngang, chưa

phải quan hệ nhân quả. Các ô thuộc nhóm trẻ (17-24) có cỡ mẫu nhỏ và tỷ lệ rất thấp nên cần đọc thận trọng.

4.8. Nhận xét Hình 8: Các yếu tố liên quan đến thu nhập

Các hình trước xét từng yếu tố hoặc từng cặp yếu tố. Hình 8 gom tất cả về một thước đo chung để trả lời câu hỏi: trong các yếu tố đã phân tích, yếu tố nào có liên hệ mạnh nhất với thu nhập. Hình (a) là ma trận tương quan giữa income_bin (1 nếu >50K) và 7 biến; hình (b) xếp hạng các biến theo độ lớn hệ số tương quan với income.



Ở hình (b), thứ tự từ mạnh đến yếu là: tình trạng kết hôn (r = +0,445), số năm học (+0,335), capital_gain_log (+0,289), tuổi (+0,234), giờ làm (+0,230), giới tính nam (+0,216) và capital_loss_log (+0,141). Tất cả đều dương, nghĩa là đều đi cùng chiều với khả năng thu nhập >50K. Hôn nhân dẫn đầu rõ rệt, cao hơn học vấn khoảng 0,11. Ba yếu tố tuổi, giờ làm và giới tính nằm sát nhau (0,216-0,234), nên thứ hạng giữa ba biến này không đủ chắc để khẳng định biến nào hơn. Về độ lớn, chỉ hôn nhân và học vấn đạt mức trung bình (khoảng 0,3-0,45), các biến còn lại ở mức yếu đến trung bình thấp.

Ma trận ở hình (a) cho thấy các biến giải thích cũng liên hệ với nhau, và đây là điểm quan trọng khi đọc xếp hạng. Giới tính nam và hôn nhân có tương quan r = +0,432, và tuổi với hôn nhân là r = +0,316. Điều này khớp với Hình 4: 61,1% nam đang kết hôn so với 15,4% nữ, nên một phần tương quan của giới tính (0,216) có thể đến từ hôn nhân. Ngược lại, học vấn gần như độc lập với tuổi (r = +0,04) và với giới tính (+0,01), nên liên hệ của học vấn với thu nhập tương đối "sạch", ít bị yếu tố khác làm nhiễu.

Cần đọc hệ số của tuổi thận trọng. Hệ số tương quan chỉ đo quan hệ đường thẳng, trong khi Hình 2 cho thấy tuổi có quan hệ chữ U ngược với thu nhập. Vì vậy r = +0,234 của tuổi nhiều khả năng đã đánh giá thấp ảnh hưởng thực của biến này. Tương tự, hôn nhân chiếm vị trí đầu bảng một phần vì biến này có thể phản ánh thu nhập hộ gia đình và đi kèm tuổi, giới tính, nên không thể hiểu là kết hôn làm tăng thu nhập.

Kết luận: nếu xếp hạng theo tương quan tuyến tính với income, hôn nhân và học vấn là hai yếu tố có liên hệ mạnh nhất, tiếp theo là capital gain, rồi nhóm tuổi, giờ làm, giới tính. Đây vẫn chỉ là tương quan từng cặp, chưa kiểm soát đồng thời các biến, nên chưa thể xem là yếu tố nhân quả hay "cốt lõi" tuyệt đối.

Nhận xét Bảng tổng kết kiểm định giả thuyết: Bảng gom kết quả của cả sáu giả thuyết: H1-H6 đều được ủng hộ (p < 1e-300). Tuy nhiên, với hơn 32.000 quan sát, p-value gần như luôn rất nhỏ, nên chỉ cho biết mối liên hệ có thật chứ chưa cho biết mạnh hay yếu, và cần xem thêm độ lớn hiệu ứng. Theo Cramér's V, hôn nhân (V = 0,447), nghề nghiệp (V = 0,352) và học vấn (V = 0,369) ở mức mạnh, giới tính (V = 0,216) ở mức trung bình. Tuổi (AUC = 0,684) và giờ làm (AUC = 0,672) cùng ở mức trung bình; vì đo bằng AUC nên không so trực tiếp với V. Chữ "Ủng hộ" chỉ có nghĩa dữ liệu phù hợp với giả thuyết, chưa phải bằng chứng nhân quả.

5. Kết luận Giai đoạn 3

	Giả thuyết	Kiểm định	p-value	Độ lớn hiệu ứng	Kết luận
0	H1 Tuổi: tăng rồi giảm (U ngược)	Mann-Whitney U	<1e-300	AUC = 0.684	Ủng hộ
1	H2 Học vấn càng cao, >50K càng cao	Chi-square + Spearman	<1e-300	V = 0.369; rho = 0.330	Ủng hộ
2	H3 Nam có >50K cao hơn nữ	Chi-square	<1e-300	V = 0.216	Ủng hộ
3	H4 Giờ làm nhiều, >50K cao hơn	Mann-Whitney U	<1e-300	AUC = 0.672	Ủng hộ
4	H5 Đang kết hôn có >50K cao hơn	Chi-square	<1e-300	V = 0.447	Ủng hộ
5	H6 Quản lý/chuyên môn cao nhất	Chi-square	<1e-300	V = 0.352	Ủng hộ

```
Ghi chú đọc kết quả:
- p-value < 0.05: mối liên hệ có ý nghĩa thống kê (với hơn 32.000 dòng, p-value gần như luôn rất nhỏ,
  nên cần xem thêm độ lớn hiệu ứng).
- Cramér's V: <0.1 yếu | 0.1-0.3 trung bình | >0.3 mạnh.
- AUC: 0.5 = không khác biệt; càng xa 0.5 thì khác biệt càng rõ.

HOÀN TẤT GIAI ĐOẠN 3.
```

Qua 8 hình và bảng tổng kết, nhóm rút ra các nhận định chính:

- Thu nhập >50K là nhóm thiểu số: chỉ 24,09% (7.839/32.537 người) vượt ngưỡng 50.000 USD/năm, nên nhóm so sánh theo tỷ lệ % trong từng nhóm với mức nền 24,09%.
- Cả 6 giả thuyết H1-H6 đều được ủng hộ (p < 1e-300), nhưng độ lớn hiệu ứng khác nhau, từ trung bình đến mạnh.
- Tuổi (H1): quan hệ chữ U ngược, tỷ lệ >50K tăng từ 1,1% (17-24 tuổi) lên đỉnh 40,1% (45-54 tuổi), rồi giảm còn 20,7% ở nhóm 65+.
- Học vấn (H2): tỷ lệ >50K tăng từ 0,0% (Preschool) đến 74,1% (Doctorate); từ bậc Associate trở lên mới vượt mức nền. Lợi thế này vẫn còn khi so sánh trong cùng nhóm tuổi (Hình 7).
- Giới tính (H3): nam 30,6% so với nữ 11,0% (gấp 2,79 lần). Chênh lệch gần như biến mất ở nhóm đang kết hôn (nữ 45,5%, nam 44,6%), cho thấy hôn nhân là yếu tố đan xen quan trọng.
- Giờ làm (H4): tỷ lệ tăng từ 6,7% (≤20 giờ) lên đỉnh 43,4% (51-60 giờ), rồi giảm nhẹ còn 36,4% ở nhóm trên 60 giờ.
- Hôn nhân và nghề nghiệp (H5, H6): người đang kết hôn (civ-spouse) đạt 44,7%, gấp 6,83 lần các nhóm còn lại; hai nghề dẫn đầu là Exec-managerial (48,4%) và Prof-specialty (44,9%).
- Tác động kết hợp (Hình 7): học vấn quyết định mức trần, tuổi quyết định thời điểm đạt mức trần đó; ô cao nhất là nhóm 45-54 tuổi có trình độ sau đại học (74,2%).
- Xếp hạng yếu tố: theo tương quan với thu nhập, hôn nhân (r = 0,445) và học vấn (r = 0,335) mạnh nhất, tiếp theo là capital gain, tuổi, giờ làm và giới tính. Học vấn gần như độc lập với

tuổi và giới tính nên là yếu tố "sạch" nhất, còn hôn nhân và giới tính có thể đan xen nhau (r = 0,432).
- Giới hạn: đây là dữ liệu cắt ngang, chỉ cho thấy mối liên hệ thống kê, chưa phải quan hệ nhân quả. Biến hôn nhân có thể phản ánh thu nhập hộ gia đình, và tương quan tuyến tính có thể đánh giá thấp ảnh hưởng của tuổi do quan hệ phi tuyến. Việc xác định yếu tố cốt lõi cần phân tích đa biến ở bước sau.

D. Giai đoạn 4: Đánh giá tác động và khuyến nghị

Ba giai đoạn đầu đã trả lời câu hỏi dữ liệu ra sao và các yếu tố nhân khẩu học liên hệ với thu nhập thế nào. Giai đoạn 4 chuyển sang câu hỏi cuối cùng của nghiên cứu: những phát hiện đó có ý nghĩa gì, có thể ứng dụng vào đâu và đáng tin đến mức nào.

Phần này gồm ba nội dung: tóm tắt các phát hiện nổi bật nhất, đề xuất giải pháp ứng dụng thực tế, và nêu giới hạn của tập dữ liệu cùng hướng mở rộng trong tương lai.

1. Tóm tắt các phát hiện nổi bật nhất

1.1. Về chất lượng dữ liệu (Giai đoạn 1 và 2)

Trước khi kết luận về thu nhập, nhóm cần xác nhận dữ liệu đủ tin cậy. Phát hiện quan trọng nhất của hai giai đoạn đầu là giá trị khuyết bị che giấu. Kiểm tra thông thường cho 0 ô khuyết, nhưng thực tế có 4.262 ô mang ký tự "?" ở ba cột: occupation (1.843 ô, 5,7%), workclass (1.836 ô, 5,6%) và native.country (583 ô, 1,8%). Tính theo dòng, có 2.399 dòng (7,37%) chứa ít nhất một ô khuyết. Nếu không phát hiện, mô hình sẽ học ra một "nghề nghiệp tên ?" không tồn tại.

Khuyết này không ngẫu nhiên mà có hệ thống và mang thông tin. Nhóm có ô khuyết chỉ có 13,9% người thu nhập >50K, trong khi nhóm đủ thông tin là 24,9%. Vì vậy nhóm chọn giữ nhãn "Unknown" thay vì điền giá trị phổ biến nhất, để không xóa mất tín hiệu này.

Sau khi làm sạch, dữ liệu còn 32.537 dòng (chỉ mất 0,07% do xóa 24 dòng trùng) và không còn ô khuyết. Các giá trị ngoại lai hợp lệ được giữ lại thay vì xóa, các cột lệch mạnh (capital.gain, capital.loss, fnlwgt) được biến đổi log1p, và tính nhất quán nội bộ được kiểm tra: education và education.num ánh xạ 1-1, chỉ có 3 bản ghi relationship–sex nghi vấn.

Một đặc điểm khác của dữ liệu cũng chi phối mọi bước sau là nhãn income mất cân bằng, với 24.698 người ≤50K (75,9%) và 7.839 người >50K (24,1%), tỷ lệ khoảng 3,15 : 1. Vì vậy toàn bộ phân tích dùng tỷ lệ >50K trong từng nhóm so với mức nền 24,1%, thay vì số đếm thô.

1.2. Về các yếu tố liên hệ với thu nhập (Giai đoạn 3)

Sáu giả thuyết đặt ra từ đầu đều được dữ liệu ủng hộ. Bảng 1 gom các con số quan trọng nhất của từng giả thuyết cùng độ lớn hiệu ứng.

Giả thuyết	Phát hiện chính	Độ lớn hiệu ứng

H1. Tuổi	Quan hệ chữ U ngược: 1,1% (17-24) → 16,8% (25-34) → 33,2% (35-44) → đỉnh 40,1% (45-54) → 32,3% (55-64) → 20,7% (65+)	AUC = 0,684 (trung bình)
H2. Học vấn	Tăng gần đơn điệu từ 0,0% (Preschool) đến 74,1% (Doctorate); Bachelors gấp 2,60 lần HS-grad; Associate là mốc đầu tiên vượt mức nền	Cramér's V = 0,369; Spearman theo nhóm bậc học = 0,976
H3. Giới tính	Nam 30,6% so với nữ 11,0% (gấp 2,79 lần); ở nhóm đang kết hôn gần ngang nhau (nữ 45,5%, nam 44,6%)	Cramér's V = 0,216
H4. Giờ làm	Tăng từ 6,7% (≤20 giờ) lên đỉnh 43,4% (51-60 giờ), giảm nhẹ còn 36,4% ở nhóm trên 60 giờ	AUC = 0,672
H5. Hôn nhân	Married-civ-spouse 44,7%, gấp 6,83 lần các nhóm còn lại gộp (6,5%)	Cramér's V = 0,447
H6. Nghề nghiệp	Exec-managerial 48,4% và Prof-specialty 44,9% dẫn đầu; Other-service chỉ 4,2%	Cramér's V = 0,352

Bảng 1. Kết quả kiểm định sáu giả thuyết

Bên cạnh các con số riêng lẻ, có hai phát hiện tổng hợp đáng chú ý hơn. Phát hiện thứ nhất là học vấn quyết định mức trần còn tuổi quyết định thời điểm đạt mức trần (Hình 7). Ở mọi nhóm tuổi, tỷ lệ >50K đều tăng theo học vấn; riêng nhóm 45-54 tăng từ 11% lên 29%, 37%, 59% rồi 74%, nên lợi thế của học vấn không chỉ do người học cao tình cờ lớn tuổi hơn. Ngược lại, người 17-24 tuổi có Bachelors chỉ đạt 2,7% trong khi nhóm 25-34 tuổi có Bachelors đạt 30,5%, cho thấy bằng cấp cần một giai đoạn tích lũy kinh nghiệm mới phát huy tác dụng.

Phát hiện thứ hai là chênh lệch giới thu hẹp mạnh khi so sánh cùng tình trạng hôn nhân. Khoảng cách thô 19,6 điểm phần trăm chỉ còn khoảng 3,9 điểm ở nhóm không kết hôn, và đảo nhẹ ở nhóm đang kết hôn (nữ cao hơn nam 0,9 điểm). Tuy vậy, nam vẫn cao hơn nữ ở mọi nhóm giờ làm, với khoảng cách lớn nhất (16,5 điểm) ở nhóm làm đúng 40 giờ, nên không thể kết luận giới tính hoàn toàn không còn liên hệ với thu nhập.

1.3. Yếu tố liên hệ mạnh nhất với thu nhập

Từ các kết quả trên, câu hỏi trọng tâm là yếu tố nào liên hệ mạnh nhất với việc một người có thu nhập trên hay dưới 50.000 USD/năm. Dựa trên hai thước đo của Giai đoạn 3 là Cramér's V cho biến phân loại và hệ số tương quan với income_bin ở Hình 8, nhóm xếp các yếu tố thành ba tầng như trong Bảng 2.

Tầng	Yếu tố	Bằng chứng	Ghi chú khi diễn giải

Mạnh nhất	Tình trạng hôn nhân	r = +0,445; V = 0,447	Có thể phản ánh thu nhập hộ gia đình, đan xen với tuổi và giới tính
Mạnh	Học vấn	r = +0,335; V = 0,369	"Sạch" nhất: gần như độc lập với tuổi (r = 0,04) và giới tính (r = 0,01)
Mạnh	Nghề nghiệp	V = 0,352	Đan xen với học vấn
Trung bình	Capital gain	r = +0,289	Chỉ 8,3% quan sát có lãi vốn; mã 99.999 là giá trị chặn trên
Trung bình	Tuổi	r = +0,234; AUC = 0,684	Hệ số tuyến tính đánh giá thấp vì quan hệ thực là chữ U ngược
Trung bình	Giờ làm	r = +0,230; AUC = 0,672	Nhân quả có thể đi hai chiều
Trung bình thấp	Giới tính	r = +0,216; V = 0,216	Một phần đi cùng hôn nhân (r giữa nam và kết hôn = 0,432)

Bảng 2. Xếp hạng các yếu tố theo mức độ liên hệ với thu nhập

Ba yếu tố tuổi, giờ làm và giới tính nằm sát nhau (0,216 đến 0,234) nên thứ hạng giữa chúng không đủ chắc. Vì vậy, kết luận trung thực nhất là nhóm yếu tố cốt lõi gồm tình trạng hôn nhân/hộ gia đình, học vấn và nghề nghiệp; tiếp theo là vốn tài chính, tuổi (kinh nghiệm) và giờ làm; còn giới tính có liên hệ riêng ở mức nhẹ đến trung bình và cần theo dõi về mặt công bằng.

Đây là xếp hạng theo liên hệ từng cặp, chưa kiểm soát đồng thời các biến. Việc khẳng định yếu tố nào "quyết định" cần đến mô hình đa biến (xem mục 3.2).

2. Đề xuất giải pháp mang tính ứng dụng thực tế

Từ các phát hiện trên, nhóm đề xuất những giải pháp dưới đây. Mỗi giải pháp bám vào một con số cụ thể và kèm chỉ số theo dõi để đánh giá hiệu quả. Vì dữ liệu chỉ cho thấy tương quan, các đề xuất được hiểu là hướng ưu tiên để thử nghiệm và đánh giá, không phải cam kết sẽ làm tăng thu nhập.

2.1. Giáo dục và đào tạo nghề

Tỷ lệ >50K của nhóm HS-grad là 16,0% và Some-college là 19,0%, đều thấp hơn mức nền 24,1%, trong khi Assoc-acdm (24,8%) và Assoc-voc (26,1%) là hai bậc đầu tiên vượt mức nền và Bachelors đạt 41,5%. Vì vậy, với người đã tốt nghiệp phổ thông, nhóm đề xuất ưu tiên các chương trình cao đẳng nghề, chứng chỉ ngắn hạn và liên thông lên đại học. Đây là bước chuyển có độ nhảy lớn nhất trong biểu đồ, lại có chi phí thấp hơn đại học bốn năm.

Hiệu quả có thể đánh giá qua tỷ lệ hoàn thành chương trình và thu nhập sau 2-3 năm so với nhóm đối chứng cùng độ tuổi. Cần lưu ý các bậc rất thấp (Preschool n=50, 1st-4th n=166) có mẫu nhỏ nên không dùng làm căn cứ chính sách.

2.2. Lộ trình sự nghiệp cho người trẻ

Nhóm 17-24 tuổi chỉ có 1,1% vượt ngưỡng, kể cả người có Bachelors cũng chỉ đạt 2,7%, trước khi nhảy lên 30,5% ở nhóm 25-34. Do đó doanh nghiệp và trường đại học nên mở rộng thực tập có hướng dẫn, chương trình quản trị tập sự và cố vấn nghề nghiệp để rút ngắn giai đoạn tích lũy. Sinh viên cũng cần hiểu rằng thu nhập khởi điểm thấp là đặc điểm chung của độ tuổi, không phải dấu hiệu của lựa chọn sai. Chỉ số theo dõi là thời gian từ lúc tốt nghiệp đến lúc đạt mức lương mục tiêu và tỷ lệ thực tập sinh được tuyển chính thức.

2.3. Nhóm 55 tuổi trở lên

Tỷ lệ >50K giảm từ đỉnh 40,1% (45-54) xuống 32,3% (55-64) và 20,7% (65+), nhưng người 65+ có Sau đại học (52,0%) và Bachelors (42,6%) vẫn cao hơn mức nền. Điều này gợi ý nên xây dựng lộ trình làm việc linh hoạt (bán thời gian, cố vấn, đào tạo người mới) cho người trình độ cao gần tuổi nghỉ hưu để giữ lại kinh nghiệm.

Với người cao tuổi học vấn thấp, cần có chính sách an sinh riêng, vì tuổi cao không bù được học vấn: nhóm 45-54 Dưới THPT chỉ đạt 11,2%.

2.4. Bình đẳng giới

Khoảng cách thô 19,6 điểm phần trăm (30,6% so với 11,0%) phần lớn đi cùng khác biệt về hôn nhân (61,1% nam đang kết hôn so với 15,4% nữ), nhưng nam vẫn cao hơn ở mọi nhóm giờ làm. Vì vậy nhóm đề xuất doanh nghiệp công bố và theo dõi khoảng cách thu nhập giữa nam và nữ đã so sánh theo cùng vị trí, giờ làm và trình độ, vì đây mới là chỉ số phản ánh đối xử công bằng. Song song đó, nên hỗ trợ chăm sóc con và chế độ làm việc linh hoạt để giảm các rào cản mà dữ liệu này không đo được nhưng có thể nằm sau khoảng cách, đồng thời minh bạch thang lương theo vị trí.

Cần lưu ý dữ liệu không cho phép kết luận nguyên nhân là phân biệt đối xử, chọn nghề hay thời gian nghỉ chăm con. Đề xuất này nhằm đo lường đúng chứ không quy kết.

2.5. Giờ làm việc

Tỷ lệ >50K đạt đỉnh ở nhóm 51-60 giờ (43,4%) rồi giảm ở nhóm trên 60 giờ (36,4%). Người có thu nhập cao thường ở vị trí quản lý, chuyên môn hoặc tự kinh doanh vốn đã làm nhiều giờ, nên chiều nhân quả có thể ngược lại. Do đó không nên dùng kết quả này để cổ vũ làm việc quá giờ, mà nên hướng tới tăng giá trị mỗi giờ làm thông qua kỹ năng và vị trí. Cũng cần lưu ý 46,7% người làm đúng 40 giờ, nên chính sách giờ làm chuẩn ảnh hưởng đến gần một nửa lực lượng lao động trong mẫu.

2.6. Nhóm không khai báo việc làm (Unknown)

Nhóm này chỉ đạt 10,4% >50K, làm trung bình 31,9 giờ/tuần và chủ yếu là người dưới 25 tuổi (34,4%) hoặc từ 65 tuổi trở lên (18,8%). Đây là nhóm đang ở ngoài hoặc ở rìa thị trường lao động chính thức, như sinh viên, người nghỉ hưu, người thất nghiệp. Các chương trình việc làm nên phân loại rõ nhóm này thay vì gộp với người đang đi làm. Với tổ chức khảo sát, nên thiết kế câu hỏi phân biệt "không đi làm" với "không khai báo", vì hai trường hợp này hiện bị mã hóa chung thành dấu "?".

2.7. Ứng dụng mô hình dự đoán thu nhập

Nếu nhóm tiếp tục xây mô hình phân loại từ bộ dữ liệu đã làm sạch (adult_encoded.csv), các phát hiện trên dẫn đến một số khuyến nghị kỹ thuật. Về đặc trưng, nên dùng hôn nhân, số năm học, nghề nghiệp, giờ làm và cờ lãi vốn; riêng tuổi nên kèm biến bình phương hoặc nhóm tuổi vì quan hệ chữ U ngược. Nên giữ một trong hai cột học vấn và cân nhắc dùng fnlwgt làm trọng số mẫu thay vì đặc trưng.

Về cách đánh giá, nên chia tập phân tầng 80/20 và dùng Precision, Recall, F1 và ROC-AUC thay vì chỉ accuracy, vì một mô hình luôn trả lời "≤50K" đã đúng khoảng 75,9%. Có thể thêm class weight hoặc SMOTE để xử lý mất cân bằng.

Về phạm vi, mô hình phù hợp để sàng lọc nhóm cần hỗ trợ việc làm hoặc đào tạo, phân khúc khách hàng ở mức tổng hợp và phân tích kịch bản chính sách. Mô hình không phù hợp để quyết định tuyển dụng, tín dụng hay mức lương của từng cá nhân, đặc biệt khi dùng sex và race, vì mô hình có thể học "đoán nữ thì thu nhập thấp" từ chênh lệch lịch sử, còn các nhóm thiểu số ít mẫu (Amer-Indian-Eskimo 311, Other 271) cho ước lượng thiếu ổn định. Vì vậy cần kiểm tra công bằng theo nhóm trước khi triển khai và cân nhắc loại các biến nhạy cảm.

2.8. Bảng tóm tắt khuyến nghị

Bảng 3 tổng hợp các đề xuất trên theo từng đối tượng, kèm phát hiện nền tảng và chỉ số theo dõi.

Đối tượng	Phát hiện nền tảng	Khuyến nghị	Chỉ số theo dõi
Người học, cơ sở đào tạo	Associate là mốc vượt mức nền (24,8-26,1%); Bachelors 41,5%	Mở rộng cao đẳng nghề, chứng chỉ ngắn hạn, liên thông	Tỷ lệ hoàn thành; thu nhập sau 2-3 năm
Người trẻ, doanh nghiệp	17-24 tuổi: 1,1%; Bachelors 17-24 tuổi: 2,7%	Thực tập có hướng dẫn, quản trị tập sự, cố vấn	Thời gian đạt mức lương mục tiêu
Người từ 55 tuổi	40,1% → 32,3% → 20,7%	Làm việc linh hoạt cho người trình độ cao; an sinh cho người học vấn thấp	Tỷ lệ tiếp tục làm việc sau 60 tuổi
Nhà tuyển dụng, nhà hoạch định	Nam 30,6% so với nữ 11,0%; nam vẫn cao hơn ở mọi nhóm giờ làm	Theo dõi khoảng cách cùng điều kiện; hỗ trợ chăm sóc con; minh bạch thang lương	Khoảng cách điều chỉnh theo vị trí và giờ làm
Người lao động, tổ chức	Đỉnh 43,4% ở 51-60 giờ, giảm ở trên 60 giờ	Tăng giá trị mỗi giờ thay vì tăng số giờ	Thu nhập/giờ

Chương trình việc làm	Nhóm Unknown 10,4%	Tiếp cận riêng; phân biệt "không đi làm" với "không khai báo"	Tỷ lệ chuyển sang việc làm chính thức
Nhóm phân tích dữ liệu	Nhãn lệch 76/24; sex và race nhạy cảm	Dùng F1, ROC-AUC; kiểm tra công bằng; không dùng cho quyết định cá nhân	Hiệu năng theo từng nhóm nhân khẩu

Bảng 3. Tóm tắt khuyến nghị theo đối tượng

3. Giới hạn của tập dữ liệu và hướng mở rộng

3.1. Các giới hạn cần nêu rõ

Để người đọc đánh giá đúng mức độ tin cậy của các khuyến nghị trên, nhóm trình bày các giới hạn theo năm nhóm: phạm vi và thời gian, thiết kế nghiên cứu, biến số, chất lượng dữ liệu và phương pháp phân tích.

Về phạm vi và thời gian, dữ liệu trích từ điều tra dân số Hoa Kỳ năm 1994, khi ngưỡng 50.000 USD, cơ cấu nghề nghiệp, vai trò giới và mặt bằng giáo dục khác hiện nay. Vì vậy kết quả chỉ có giá trị minh họa phương pháp, không nên suy rộng cho Việt Nam hay cho thực tế hiện tại. Con số 50.000 USD cũng chưa được điều chỉnh theo lạm phát hay chi phí sinh hoạt từng vùng.

Về thiết kế nghiên cứu, dữ liệu là cắt ngang nên chỉ cho thấy khác biệt giữa các nhóm tại một thời điểm, không theo dõi cùng một người theo thời gian. Quan hệ chữ U ngược của tuổi có thể một phần là hiệu ứng thế hệ (người 65+ năm 1994 có học vấn trung bình thấp hơn người trẻ) chứ không chỉ là hiệu ứng tuổi. Dữ liệu cũng chỉ cho thấy tương quan chứ không chứng minh nhân quả, vì kết hôn, giờ làm và học vấn đều có thể đi cùng thu nhập do những yếu tố ẩn không có trong dữ liệu.

Ngoài ra, nhãn thu nhập là nhị phân nên người kiếm 51K và 200K được coi như nhau, người kiếm 49K và 10K cũng vậy. Với người đã kết hôn, thu nhập còn có thể được ghi nhận ở mức hộ gia đình, nên vị trí đầu bảng của biến hôn nhân (r = 0,445) có thể bị thổi phồng và kết quả "nữ 45,5% so với nam 44,6%" ở nhóm kết hôn cần đọc thận trọng.

Về biến số, bộ dữ liệu thiếu nhiều yếu tố quan trọng như số năm kinh nghiệm, ngành nghề chi tiết, quy mô doanh nghiệp, vùng miền, chất lượng trường học, thời gian nghỉ làm chăm con, tài sản và thừa kế, nên không thể tách riêng tác động của từng yếu tố. Thêm vào đó, education và education.num trùng thông tin, còn fnlwgt là trọng số điều tra chứ không phải đặc điểm cá nhân.

Về chất lượng dữ liệu, khuyết mang tính hệ thống: 7,37% số dòng khuyết nằm ở nhóm có đặc điểm riêng, và việc gán "Unknown" là một lựa chọn chưa kiểm chứng được nhóm này thật sự không đi làm hay chỉ không khai báo. Một số giá trị còn bị chặn trên (top-coded): capital.gain = 99.999 (159 dòng, 100% thuộc nhóm >50K) là mã chặn chứ không phải số tiền thật, còn hours.per.week và age cũng bị gộp ở các giá trị cực (99 giờ, 90 tuổi). Vì mã 99.999 dự đoán nhãn hoàn hảo, không được diễn giải thành "lãi vốn lớn đảm bảo thu nhập cao".

Bên cạnh đó, 24 dòng trùng và 3 bản ghi relationship–sex nghi vấn không thể xác minh do không có cột ID, nhưng số lượng rất nhỏ (0,07% và 0,009%). Một số nhóm có cỡ

mẫu nhỏ nên tỷ lệ kém tin cậy: Married-AF-spouse (n=23), Armed-Forces (n=9), Preschool (n=50); ô 17-24 × Sau đại học bị bỏ khỏi heatmap vì n < 30.

Về phương pháp phân tích, Giai đoạn 3 là thống kê mô tả và kiểm định từng cặp biến, chưa kiểm soát đồng thời nhiều biến nên chưa tách được hiệu ứng riêng của từng yếu tố. Với hơn 32.000 quan sát, p-value gần như luôn rất nhỏ (< 1e-300), vì vậy chỉ cho biết mối liên hệ có thật và cần dựa vào độ lớn hiệu ứng (Cramér's V, AUC) để đánh giá mạnh yếu. Hệ số tương quan Pearson chỉ đo quan hệ đường thẳng nên đánh giá thấp ảnh hưởng của tuổi.

Các phân tích cũng chưa dùng trọng số fnlwgt, nên kết quả mô tả mẫu chứ chưa chắc đại diện cho toàn bộ dân số Hoa Kỳ. Cuối cùng, các biến race và native.country chưa được phân tích sâu do nhạy cảm và cỡ mẫu nhóm thiểu số nhỏ.

3.2. Hướng mở rộng trong tương lai

Tương ứng với các giới hạn trên, nhóm đề xuất những hướng mở rộng trong Bảng 4. Mỗi hướng nêu rõ giới hạn mà nó giải quyết và cách thực hiện.

Hướng mở rộng	Giải quyết giới hạn nào	Cách thực hiện
Mô hình đa biến	Chỉ có tương quan từng cặp; chưa xác định yếu tố cốt lõi	Hồi quy logistic và đọc odds ratio để kiểm soát đồng thời tuổi, học vấn, hôn nhân, giờ làm, giới tính; so sánh với Decision Tree và Random Forest; dùng feature importance và SHAP để xếp hạng yếu tố
Tương tác giữa các yếu tố	Hình 7 gợi ý học vấn và tuổi tác động kết hợp	Thêm số hạng tương tác (tuổi × học vấn, giới tính × hôn nhân) vào mô hình; vẽ biểu đồ tương tác
Phân tích công bằng thuật toán	Nguy cơ thiên lệch với sex và race	Đo demographic parity, equalized odds theo nhóm; so sánh mô hình có và không có biến nhạy cảm
Dùng trọng số fnlwgt	Mẫu chưa chắc đại diện dân số	Tính lại tỷ lệ >50K có trọng số và so với kết quả không trọng số
Thu nhập liên tục thay vì nhị phân	Mất thông tin do ngưỡng 50K	Dùng bộ dữ liệu có thu nhập dạng số; chạy hồi quy trên log thu nhập
Dữ liệu mới hoặc theo thời gian	Dữ liệu 1994, cắt ngang	Dùng các cuộc điều tra gần đây của Hoa Kỳ để kiểm tra các quy luật còn đúng không; so sánh theo thế hệ để tách hiệu ứng tuổi và hiệu ứng thế hệ

Dữ liệu trong nước	Không suy rộng được cho Việt Nam	Lặp lại quy trình bốn giai đoạn trên một bộ khảo sát mức sống hộ gia đình của Việt Nam, điều chỉnh ngưỡng thu nhập cho phù hợp
Bổ sung biến còn thiếu	Biến ẩn gây nhiễu	Thu thập kinh nghiệm làm việc, ngành, vùng, quy mô doanh nghiệp để kiểm tra vai trò của hôn nhân và giới tính sau khi kiểm soát các biến này
Làm rõ giá trị "?"	Không phân biệt được "không đi làm" với "không khai báo"	Đối chiếu với nguồn gốc dữ liệu hoặc bổ sung câu hỏi khảo sát

Bảng 4. Hướng mở rộng tương ứng với từng giới hạn

4. Kết luận chung của bài

Thứ nhất, dữ liệu đủ tin cậy sau khi được xử lý đúng. Điểm then chốt là phát hiện 4.262 ô khuyết bị che bởi dấu "?" và nhận ra khuyết này có hệ thống, nên dữ liệu khuyết được giữ thành nhóm "Unknown" thay vì điền giá trị phổ biến nhất hay xóa dòng.

Thứ hai, thu nhập >50K gắn với một nhóm yếu tố rõ ràng. Hôn nhân/hộ gia đình, học vấn và nghề nghiệp có liên hệ mạnh nhất (V từ 0,35 đến 0,45), tuổi, giờ làm và vốn tài chính ở mức trung bình, còn giới tính ở mức nhẹ đến trung bình nhưng có ý nghĩa về công bằng. Trong đó học vấn là yếu tố "sạch" nhất vì gần như độc lập với tuổi và giới tính; học vấn quyết định mức trần, còn tuổi quyết định thời điểm đạt mức trần.

Thứ ba, kết quả có giá trị chỉ dẫn chứ chưa phải bằng chứng nhân quả, vì dữ liệu cũ (1994), cắt ngang, thiếu nhiều biến và thu nhập chỉ ở dạng nhị phân. Do đó các khuyến nghị ở mục 2 nên được hiểu là hướng ưu tiên để thử nghiệm và đo lường. Bước tiếp theo hợp lý nhất là xây dựng mô hình đa biến kèm kiểm tra công bằng, để biến "nhóm yếu tố liên quan" thành "yếu tố cốt lõi" có căn cứ chặt chẽ hơn.